

BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC KINH TẾ KỸ THUẬT CÔNG NGHIỆP
KHOA KHOA HỌC ỨNG DỤNG



BÁO CÁO HỌC PHẦN
PHÂN TÍCH DỮ LIỆU LỚN

ĐỀ TÀI:
PHÂN TÍCH BÀI BÁO PHÂN LOẠI HẠT HIGGS BOSON

Sinh viên thực hiện:

Nguyễn Tuấn Hùng 22174600118
Nguyễn Bá Long 22174600034
Nguyễn Quang Huy 22174600113

Giảng viên hướng dẫn: Lê Hằng Anh

Hà Nội, 2026

BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC KINH TẾ KỸ THUẬT CÔNG NGHIỆP
KHOA KHOA HỌC ỨNG DỤNG



BÁO CÁO HỌC PHẦN
PHÂN TÍCH DỮ LIỆU LỚN

ĐỀ TÀI:
PHÂN TÍCH BÀI BÁO PHÂN LOẠI HẠT HIGGS BOSON

Sinh viên thực hiện:

Nguyễn Tuấn Hùng 22174600118
Nguyễn Bá Long 22174600034
Nguyễn Quang Huy 22174600113

Giảng viên hướng dẫn: Lê Hằng Anh

Hà Nội, 2026

MỤC LỤC

DANH SÁCH CÁC KÝ HIỆU, TỪ VIẾT TẮT	iii
DANH SÁCH HÌNH VẼ	iv
DANH SÁCH BẢNG BIỂU	v
LỜI MỞ ĐẦU	vi
CHƯƠNG 1: TỔNG QUAN VỀ BÀI TOÁN VÀ BÀI BÁO GỐC	1
1.1. Giới thiệu bài toán phân loại hạt Higgs Boson	1
1.2. Tóm tắt bài báo gốc (IRJET 2021):	1
1.3. Thiết kế quy trình thực nghiệm	3
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT	4
2.1. Tiền xử lý dữ liệu	4
2.2. Tổng quan về các mô hình học máy trong bài báo	5
2.3. Các phương thức đánh giá	7
CHƯƠNG 3: THỰC NGHIỆM VÀ TÁI HIỆN BÀI BÁO	10
3.1. Dữ liệu và tiền xử lý dữ liệu	10
3.1.1. Tổng quan về bộ dữ liệu hạt Higgs Boson	10
3.1.2. Các bước triển khai tiền xử lý dữ liệu (Data Pre-processing)	10
3.2. Phân tích dữ liệu khám phá (EDA)	12
3.2.1 Phân tích tổng quan	13
3.2.2. Phân tích phân phối các biến	14
3.3. Quá trình huấn luyện	17
3.4. Phân tích kết quả đạt được	24
CHƯƠNG 4: CẢI TIẾN VÀ MỞ RỘNG	27
4.1. Hạn chế trong bài báo gốc và phương pháp cải thiện	27
4.1.1. Những hạn chế trong bài báo gốc	27

4.1.2. Những cải tiến sẽ thực hiện	28
4.2. Thiết lập dữ liệu và môi trường	29
4.2.1. Dữ liệu và xử lý dữ liệu	29
4.2.2. Thiết lập môi trường	31
4.3. Huấn luyện mô hình	33
4.3.1. Các mô hình học máy	33
4.3.2. Triển khai mô hình DNN5	34
4.3.3. Kết quả huấn luyện	36
4.4. Trực quan hoá hiệu quả cải tiến	38
4.4.1. So sánh kết quả các mô hình cũ	38
4.4.2. Đánh giá các mô hình mới	43
4.4.3. Tổng kết những cải thiện đạt được	48
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	50
5.1. Tổng quan bài báo gốc	50
5.2. Kết quả cải tiến đạt được	51
5.3. Phương hướng phát triển dự án trong tương lai	52
TÀI LIỆU THAM KHẢO	54

DANH SÁCH CÁC KÝ HIỆU, TỪ VIẾT TẮT

Từ viết tắt	Ý nghĩa đầy đủ
UNETI	Trường Đại học Kinh tế - Kỹ thuật Công nghiệp
LHC	Máy gia tốc hạt Lớn (Large Hadron Collider)
CERN	Tổ chức Nghiên cứu Hạt nhân Châu Âu
UCI	Kho dữ liệu công cộng UCI (University of California, Irvine)
SMOTE	Synthetic Minority Over-sampling Technique (Kỹ thuật lấy mẫu vượt trội)
AUC	Area Under the Curve (Diện tích dưới đường cong)
ROC	Receiver Operating Characteristic (Đặc tính Hoạt động Máy thu)
BCE	Binary Cross Entropy (Hàm mất mát Entropy chéo nhị phân)
DT	Decision Tree (Cây quyết định) [cite: 46]
LR	Linear/Logistic Regression (Hồi quy tuyến tính / Hồi quy Logistic)
RNN	Recurrent Neural Network (Mạng nơ-ron hồi quy)
LSTM	Long Short-Term Memory (Mạng bộ nhớ ngắn hạn dài)
SVM	Support Vector Machine (Máy vector hỗ trợ)
RF	Random Forest (Rừng ngẫu nhiên)
GBT	Gradient Boosted Trees (Cây tăng cường độ dốc)
XGBoost	Extreme Gradient Boosting (Cực trị tăng cường độ dốc)
DNN	Deep Neural Network (Mạng nơ-ron sâu)
SM	Standard Model (Mô hình Chuẩn)
SIG / s	Signal (Sự kiện tín hiệu)
BKG / b	Background (Sự kiện nhiễu nền)
pT	Transverse momentum (Động lượng ngang)
ET	Missing transverse energy (Năng lượng ngang bị thiếu hụt)
I/O	Input / Output (Đầu vào / Đầu ra)

DANH SÁCH HÌNH VẼ

1	Biểu đồ thiết kế luồng hoạt động.	3
2	Biểu đồ phân chia cấu trúc dữ liệu.	5
3	Biểu đồ cấu trúc cây Decision Tree.	6
4	Biểu đồ thể hiện cách đánh giá AUC - ROC.	9
5	Biểu đồ phân phối các biến dữ liệu.	13
6	Biểu đồ phân phối (1)	14
7	Biểu đồ phân phối (2)	16
8	Biểu đồ cấu trúc cây quyết định.	20
9	Biểu đồ learning curver và training loss của mô hình LSTM.	23
10	Biểu đồ phân chia cấu trúc dữ liệu cải tiến.	28
11	Biểu đồ luồng hoạt động (1)	31
12	Biểu đồ luồng hoạt động (2)	32
13	Biểu đồ Learning curve và training loss của mô hình DNN5	36
14	Biểu đồ so sánh cải thiện độ chính xác LR và DT.	38
15	Biểu đồ so sánh độ chính xác các mô hình.	39
16	Biểu đồ so sánh đường cong ROC của các mô hình.	40
17	Biểu đồ so sánh ma trận tương quan.	41
18	Biểu đồ so sánh thời gian huấn luyện mô hình.	42
19	Biểu đồ tổng quát chỉ số đánh giá các mô hình	43
20	Biểu đồ chỉ số AUC-ROC các mô hình.	44
21	Biểu đồ radar chỉ số các mô hình.	45
22	Biểu đồ ma trận nhầm lẫn mô hình Random Forest.	46
23	Biểu đồ ma trận nhầm lẫn mô hình Gradient Boost Tree.	47
24	Biểu đồ Features Importance mô hình Gradient Boost Tree.	47

DANH SÁCH BẢNG BIỂU

1	Phát hiện Noisy Data (Outliers — IQR method)	11
2	Kết quả huấn luyện mô hình Linear Regression	18
3	Ma trận nhầm lẫn mô hình Linear Regression	19
4	Kết quả huấn luyện mô hình Decision Tree	20
5	Ma trận nhầm lẫn mô hình Decision Tree	21
6	Kiến trúc và tham số của mô hình LSTM	22
7	Kết quả huấn luyện mô hình LSTM	23
8	Ma trận nhầm lẫn mô hình LSTM	24
9	Bảng tổng hợp và đối chiếu kết quả các mô hình	25
10	Thông tin tổng quan về bộ dữ liệu đầy đủ.	30
11	Kiến trúc mạng nơ-ron sâu 5 tầng (DNN 5-layer)	35
12	Tổng hợp kết quả đánh giá các mô hình trên tập dữ liệu 28 đặc trưng	36

LỜI MỞ ĐẦU

Trong kỷ nguyên công nghệ số hiện nay, dữ liệu lớn (Big Data) đã và đang trở thành động lực cốt lõi thúc đẩy sự phát triển của mọi lĩnh vực khoa học, đặc biệt là trong vật lý năng lượng cao. Tại Tổ chức Nghiên cứu Hạt nhân Châu Âu (CERN), Máy gia tốc hạt Lớn (LHC) liên tục tạo ra hàng tỷ sự kiện va chạm mỗi giây, hình thành một khối lượng dữ liệu thực nghiệm khổng lồ. Một trong những thách thức vĩ đại nhất của vật lý hiện đại là việc nhận diện tín hiệu hạt Higgs Boson – hạt cơ bản giải thích cơ chế hình thành khối lượng của vạn vật – giữa lớp nhiễu nền (background) dày đặc của các tàn dư va chạm. Với tỷ lệ xuất hiện cực kỳ hiếm hoi, việc phân loại chính xác tín hiệu này đòi hỏi các phương pháp xử lý dữ liệu đột phá, vượt ra ngoài giới hạn của các kỹ thuật thống kê truyền thống.

Nhận thức được tầm quan trọng và tính ứng dụng của vấn đề, nhóm chúng em đã quyết định lựa chọn đề tài "Phân tích bài báo phân loại hạt Higgs Boson" làm đề án cho học phần Phân tích Dữ liệu lớn. Mục tiêu của báo cáo không chỉ dừng lại ở việc tái hiện quy trình mô hình hóa từ nghiên cứu gốc, mà còn tập trung vào việc áp dụng các kỹ thuật điện toán phân tán và kiến trúc học sâu tiên tiến nhằm cải thiện toàn diện hiệu năng phân loại.

Để hoàn thành được đề án này, nhóm xin gửi lời tri ân chân thành và sâu sắc nhất đến giảng viên hướng dẫn Lê Hằng Anh. Nhờ sự tận tâm giảng dạy, truyền đạt kiến thức và những định hướng chuyên môn quý báu của cô trong suốt quá trình học tập bộ môn Phân tích Dữ liệu lớn, nhóm đã có nền tảng vững chắc để tiếp cận, phân tích và giải quyết một bài toán dữ liệu phức tạp một cách hệ thống và khoa học nhất.

CHƯƠNG 1: TỔNG QUAN VỀ BÀI TOÁN VÀ BÀI BÁO GỐC

1.1. Giới thiệu bài toán phân loại hạt Higgs Boson

Trong lĩnh vực vật lý năng lượng cao, việc phát hiện và nghiên cứu hạt Higgs Boson đóng vai trò cốt lõi trong việc củng cố Mô hình Chuẩn (Standard Model), qua đó giải thích cơ chế hình thành khối lượng của các hạt cơ bản. Tại Máy gia tốc hạt Lớn (LHC) thuộc Tổ chức Nghiên cứu Hạt nhân Châu Âu (CERN), các thí nghiệm va chạm proton ở mức năng lượng cực cao tạo ra hàng tỷ sự kiện mỗi giây. Tuy nhiên, hạt Higgs có thời gian tồn tại vô cùng ngắn và gần như ngay lập tức phân rã thành các hạt thứ cấp. Do đó, sự tồn tại của hạt Higgs không thể được quan sát trực tiếp mà chỉ có thể được suy luận thông qua việc đo lường và phân tích các đặc trưng động học của tàn dư sau va chạm.

Thách thức lớn nhất trong quá trình xử lý dữ liệu từ LHC là sự chênh lệch khổng lồ giữa các sự kiện va chạm thông thường và các sự kiện thực sự sinh ra hạt Higgs. Đại đa số các va chạm chỉ tạo ra các hạt cơ bản đã biết, hình thành một khối lượng dữ liệu khổng lồ được gọi là "nhiều nền" (Background). Trong khi đó, chỉ một tỷ lệ cực kỳ nhỏ (vài phần tỷ) các vụ va chạm mới sinh ra hạt Higgs, được định nghĩa là "tín hiệu" (Signal). Việc tách lọc thành công các sự kiện tín hiệu hiếm hoi này khỏi lớp nhiễu nền dày đặc là một rào cản lớn đối với các kỹ thuật lọc thủ công hay phương pháp thống kê truyền thống.

Để giải quyết bài toán xử lý khối lượng dữ liệu lớn này, phương pháp tiếp cận Học máy (Machine Learning) được áp dụng bằng cách mô hình hóa quá trình tìm kiếm thành một bài toán phân loại nhị phân (Binary Classification). Ở bài toán này, đầu vào của các thuật toán là các vector chứa tập hợp đặc trưng (features) đại diện cho các thông số động học của hạt, chẳng hạn như năng lượng, động lượng, hay góc lệch. Hệ thống mô hình sẽ tiến hành phân tích ma trận dữ liệu nhiều chiều này để đưa ra quyết định phân loại cho từng sự kiện va chạm: Nhãn 1 (Signal - biểu thị sự hiện diện của hạt Higgs) hoặc Nhãn 0 (Background - biểu thị nhiễu nền). Việc tối ưu hóa bài toán phân loại này giúp các nhà nghiên cứu loại bỏ nhiễu dư thừa, giảm thiểu sai số dương tính giả, và cô lập chính xác các dữ liệu mang tính đột phá để phục vụ cho các nghiên cứu chuyên sâu về sau.

1.2. Tóm tắt bài báo gốc (IRJET 2021):

Cách thức tiếp cận vấn đề của nhóm tác giả:

Bài nghiên cứu tập trung giải quyết bài toán phân loại hạt Higgs Boson thông qua việc ứng dụng các phương pháp Học máy (Machine Learning). Mục tiêu cốt lõi của nghiên cứu là vượt qua thách thức lớn trong vật lý năng lượng cao: phân tách thành công các tín hiệu sinh ra từ sự phân rã của các hạt ngoại lai khỏi lớp nhiễu nền dày đặc được tạo ra bởi các hạt đã biết từ các thí nghiệm trước.

đó. Để thực hiện điều này, nhóm tác giả đã thiết lập một quy trình làm việc chuẩn hóa của học máy bao gồm năm giai đoạn chính: Thu thập dữ liệu, Tiền xử lý dữ liệu, Nghiên cứu mô hình, Huấn luyện và Kiểm thử mô hình, và Đánh giá. Trong bước mô hình hóa để dự đoán đầu ra là tín hiệu hoặc nhiễu nền, họ đã áp dụng phương pháp học có giám sát (Supervised Learning) với các thuật toán phân loại và hồi quy. Ba thuật toán chính được lựa chọn để thử nghiệm và đối chiếu bao gồm: Cây quyết định (Decision Tree - DT), Hồi quy tuyến tính (Linear/Logistic Regression), và cấu trúc Mạng bộ nhớ ngắn hạn dài (Long Short-Term Memory - LSTM). Đặc biệt, nghiên cứu không chỉ dừng ở bước đánh giá mà còn tiến hành triển khai (deployment) mô hình tốt nhất thành một ứng dụng web (webapp) thông qua công cụ Streamlit và vận hành trên nền tảng đám mây Heroku để tăng tính ứng dụng thực tiễn.

Đặc điểm tập dữ liệu sử dụng:

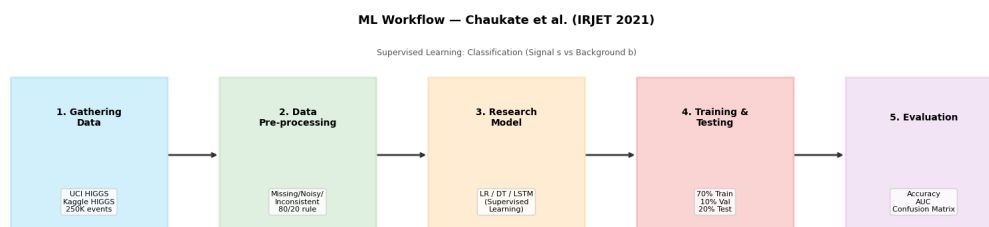
Phục vụ cho quá trình thực nghiệm, nghiên cứu sử dụng tập dữ liệu hạt Higgs quy mô lớn được thu thập từ kho dữ liệu công cộng UCI và nền tảng Kaggle. Toàn bộ cơ sở dữ liệu này bao gồm 250.000 sự kiện được ghi nhận. Dữ liệu mô phỏng các sự kiện tín hiệu và nhiễu nền này được phân bố trong một không gian đặc trưng gồm 8 chiều (8-dimensional feature space). Mỗi điểm dữ liệu của sự kiện đều được hệ thống cấp một mã định danh (ID) và một trọng số (weight) đi kèm. Trong tập dữ liệu huấn luyện, mỗi sự kiện được phân định rõ ràng bằng một trong hai nhãn: nhãn "s" đại diện cho sự kiện tín hiệu (signal) và nhãn "b" đại diện cho sự kiện nhiễu nền (background). Tám thuộc tính động học làm đầu vào cho mô hình đều là các giá trị thực, bao hàm các thông số vật lý quan trọng như: khối lượng hạt ước lượng, khối lượng bất biến của hạt hadronic tau và lepton, tổng vector động lượng ngang của hạt hadronic tau, độ tập trung của góc phương vị, độ giả nhanh (pseudo-rapidity) của lepton, cùng với số lượng các luồng hạt (jets) và đặc tính của chúng.

Kết quả thực nghiệm chính:

Nhóm nghiên cứu đánh giá mức độ hiệu quả của mô hình thông qua ma trận nhầm lẫn (confusion matrix), dựa trên các chỉ số như True Positives và True Negatives để xác định độ chính xác tổng thể. Kết luận tổng quan cho thấy việc áp dụng mô hình Học máy có khả năng phát hiện tín hiệu hạt Higgs hoặc phân loại nhiễu nền với độ chính xác cao, đồng thời rút ngắn đáng kể thời gian xử lý so với các phương pháp thủ công. Về mặt hiệu năng cụ thể của từng thuật toán, mô hình mạng nơ-ron LSTM đã thể hiện sự vượt trội rõ rệt nhất trong bài toán khám phá hạt Higgs thực tế khi đạt được độ chính xác lên đến 79%. Thành tích của LSTM bỏ xa các phương pháp phân loại khác được thử nghiệm cùng điều kiện; cụ thể thuật toán Cây quyết định (Decision Tree) chỉ đạt mức độ chính xác 72%, và thuật toán Hồi quy tuyến tính (Linear Regression) cho kết quả thấp nhất với 67%.

1.3. Thiết kế quy trình thực nghiệm

Quy trình thực nghiệm học máy trong nghiên cứu được thiết kế một cách hệ thống thông qua năm giai đoạn nối tiếp nhau nhằm đảm bảo tính chặt chẽ từ khâu tiếp nhận dữ liệu đến khi đánh giá mô hình.



Hình 1: Biểu đồ thiết kế luồng hoạt động.

Thu thập và Tiền xử lý dữ liệu:

Giai đoạn mở đầu là quá trình thu thập tập dữ liệu lớn từ các kho lưu trữ uy tín như UCI và Kaggle. Nhận thấy dữ liệu thô trong thực tế thường chứa nhiều, các giá trị ngoại lai hoặc dữ liệu bị thiếu sót, bước tiền xử lý (Data pre-processing) được đặt lên hàng đầu. Dựa trên nguyên tắc 80/20, quá trình làm sạch này chiếm phần lớn thời lượng nghiên cứu nhằm chuyển đổi dữ liệu thô thành một tập dữ liệu chuẩn mực, tạo tiền đề cải thiện độ chính xác cho mô hình.

Nghiên cứu và Huấn luyện mô hình:

Tiếp theo, dựa trên đặc thù dữ liệu đã được gán nhãn sẵn, nhóm nghiên cứu lựa chọn phương pháp Học có giám sát (Supervised Learning) với các thuật toán phân loại. Để tiến hành huấn luyện, tập dữ liệu được phân chia chiến lược thành ba phần: tập huấn luyện (training set) để thuật toán học các tham số, tập xác thực (validation set) kết hợp kỹ thuật kiểm chứng chéo 10 lần (10-fold cross validation) để tinh chỉnh mô hình, và tập kiểm thử (testing set). Việc huấn luyện tuân thủ nguyên tắc cách ly hoàn toàn tập kiểm thử để đảm bảo tính khách quan.

Đánh giá hiệu suất:

Tại giai đoạn cuối, mô hình hoàn thiện được chạy trên dữ liệu của tập kiểm thử chưa từng thấy. Hiệu suất và độ tin cậy được đo lường chi tiết thông qua Ma trận nhầm lẫn (Confusion Matrix). Bằng cách phân tích các chỉ số Dương tính thật (True Positives) và Âm tính thật (True Negatives), nghiên cứu tiến hành tính toán độ chính xác tổng thể (Accuracy), từ đó xác định phương án mô hình học máy tối ưu nhất để triển khai.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Tiền xử lý dữ liệu

Trong khuôn khổ thiết lập mô hình học máy cho bài toán phân loại hạt Higgs Boson, giai đoạn tiền xử lý dữ liệu được thực hiện một cách tuần tự và nghiêm ngặt nhằm đảm bảo tính chính xác cho các thuật toán. Khởi đầu quy trình, hệ thống tiến hành rà soát tính toàn vẹn của tập dữ liệu thông qua các kỹ thuật kiểm đếm giá trị khuyết thiếu (*Missing Data*) và loại bỏ các bản ghi trùng lặp (*Inconsistent Data*). Bước lọc ban đầu này đóng vai trò thiết yếu trong việc loại trừ các yếu tố gây nhiễu cơ bản trước khi can thiệp sâu hơn vào cấu trúc phân phối của 8 đặc trưng động học.

Xử lý giá trị ngoại lai:

Thách thức trọng tâm trong khâu làm sạch dữ liệu là việc giải quyết các tập dữ liệu nhiễu (*Noisy Data*), cụ thể là xử lý các giá trị ngoại lai. Quá trình này được triển khai qua hai giai đoạn: phát hiện và giới hạn. Để định vị ngoại lai, quy trình áp dụng phương pháp thống kê Khoảng tứ phân vị (*Interquartile Range - IQR*). Hệ thống sẽ tính toán các điểm tứ phân vị thứ nhất (Q_1) và thứ ba (Q_3) cho từng biến. Bất kỳ giá trị nào vi phạm giới hạn an toàn sau đây đều được gán cờ là dữ liệu ngoại lai:

$$[Q_1 - 1.5 \times IQR, \quad Q_3 + 1.5 \times IQR] \quad (1)$$

Tuy nhiên, thay vì xóa bỏ hoàn toàn các hàng dữ liệu chứa ngoại lai (điều có thể làm hao hụt lượng thông tin quý giá về các sự kiện va chạm), kỹ thuật *Winsorization* (Capping) được lựa chọn để can thiệp. Toàn bộ các giá trị cực đoan này được giới hạn (*clip*) bằng cách ép về bách phân vị thứ 1 (chặn dưới) và bách phân vị thứ 99 (chặn trên). Kỹ thuật này giúp trung hòa tác động làm lệch mô hình của các ngoại lai mà vẫn bảo toàn nguyên vẹn kích thước của tập dữ liệu.

Chuẩn hoá và phân tách dữ liệu:


Sau khi làm sạch, dữ liệu được chuyển sang giai đoạn Chuẩn hóa đặc trưng (*Feature Scaling*) bằng công cụ *StandardScaler*. Do các đặc trưng đầu vào sở hữu dải giá trị và thang đo hoàn toàn khác biệt, chuẩn hóa là thao tác bắt buộc để triệt tiêu sự mất cân bằng. Phương pháp này biến đổi tuyến tính các giá trị sao cho mỗi biến đều tuân thủ đặc tính:

- Giá trị trung bình: $\mu = 0$
- Độ lệch chuẩn: $\sigma = 1$

Cuối cùng, dữ liệu sạch được phân tách có cấu trúc (*stratified split*) thành ba tập phục vụ cho các giai đoạn khác nhau của mô hình:

- **Tập Huấn luyện (Training set):** 70%
- **Tập Xác thực (Validation set):** 10%
- **Tập Kiểm thử (Test set):** 20%

Sự phân chia này tạo nền tảng đồng nhất và tin cậy cho khâu mô hình hóa phía sau.



Hình 2: Biểu đồ phân chia cấu trúc dữ liệu.

2.2. Tổng quan về các mô hình học máy trong bài báo

Để xây dựng các hệ thống phân loại dữ liệu hiệu quả, đặc biệt là trong các bài toán nhị phân phức tạp như tách lọc tín hiệu vật lý khỏi nhiễu nền, việc thấu hiểu cơ chế của các thuật toán Học máy (*Machine Learning*) đóng vai trò cốt lõi. Trong các phương pháp tiếp cận phổ biến hiện nay, Hồi quy, Cây quyết định và Mạng nơ-ron LSTM là ba cấu trúc tiêu biểu, đại diện cho những trường phái giải quyết từ cơ bản đến chuyên sâu.

Hồi quy (Linear / Logistic Regression):

Trong bối cảnh phân loại, thuật toán Hồi quy (thường được triển khai dưới dạng *Logistic Regression*) là một phương pháp phân loại có giám sát điển hình. Dù mang tên gọi là "hồi quy", bản chất của thuật toán này là thiết lập một mô hình để dự báo xác suất một điểm dữ liệu nhất định thuộc về một nhãn phân loại cụ thể (ví dụ: nhãn "1" thay vì nhãn "0").


Để thực hiện điều này, thuật toán giả định dữ liệu tuân theo một phân bố tuyến tính và sử dụng hàm kích hoạt Sigmoid để ánh xạ các giá trị đầu ra nằm trong khoảng liên tục từ 0 đến 1:

$$f(z) = \frac{1}{1 + e^{-z}} \quad (2)$$

Dựa trên một giá trị ngưỡng (*threshold*) được thiết lập sẵn, mô hình sẽ chuyển đổi các xác suất này thành một kết quả phân loại nhị phân mang tính rời rạc cuối cùng.

Thuật toán Cây quyết định (Decision Tree):

Cây quyết định (*Decision Tree*) là một phương pháp linh hoạt, phi tham số và không bị ràng buộc bởi các giả định về phân phối xác suất. Mô hình này mô phỏng quá trình tư duy logic của con người dưới dạng một cấu trúc lưu đồ (*flowchart*).



Hình 3: Biểu đồ cấu trúc cây Decision Tree.

Bắt đầu từ nút gốc (*root node*), dữ liệu được dẫn qua các nút nội bộ (*internal nodes*) đại diện cho các đặc trưng của dữ liệu. Tại mỗi nút, thuật toán áp dụng cơ chế phân vùng đệ quy (*recursive partitioning*) để rẽ nhánh dựa trên các luật quyết định (*decision rules*). Quá trình này tiếp diễn cho đến khi tập dữ liệu hội tụ tại các nút lá (*leaf nodes*), nơi chứa nhãn dự đoán cuối cùng. Nhờ cấu trúc này, Cây quyết định rất dễ diễn dịch và có khả năng xử lý hiệu quả các tập dữ liệu có số chiều cao.

Mạng nơ-ron bộ nhớ ngắn hạn dài (Long Short-Term Memory - LSTM):

LSTM là một kiến trúc mạng nơ-ron hồi quy (*Recurrent Neural Network - RNN*) tiên tiến. Điểm đột phá của LSTM nằm ở khả năng giải quyết triệt để vấn đề biến mất đạo hàm (*vanishing gradient*) và hiện tượng phụ thuộc dài hạn vốn là nhược điểm của các mạng RNN truyền thống.

Trong khi RNN thông thường có xu hướng quên mất các thông tin cũ khi khoảng cách dữ liệu tăng lên, LSTM được thiết kế để duy trì và ghi nhớ thông tin trong một khoảng thời gian dài thông qua cơ chế "cổng" (*gates*). Cấu trúc cốt lõi của nó bao gồm các tế bào bộ nhớ (*cells*) được kiểm soát bởi:

- Cổng quên (*Forget gate*)
- Cổng vào (*Input gate*)
- Cổng ra (*Output gate*)

Sự kiểm soát luồng thông tin tối ưu này giúp LSTM trở thành công cụ mạnh mẽ để xử lý các dữ liệu phức tạp, đặc biệt là dữ liệu có tính chất chuỗi thời gian (*time-series*) hoặc các chuỗi sự kiện va chạm hạt trong vật lý.

2.3. Các phương thức đánh giá

Trong lĩnh vực Học máy, đặc biệt là với các bài toán phân loại nhị phân, việc chỉ sử dụng một thước đo duy nhất hiếm khi phản ánh toàn diện năng lực dự đoán của thuật toán. Để thẩm định chất lượng mô hình một cách khách quan, hệ thống các thang đo bao gồm Ma trận nhầm lẫn (Confusion Matrix), Độ chính xác tổng thể (Accuracy) và Diện tích dưới đường cong (AUC) được coi là quy chuẩn bắt buộc.

Ma trận nhầm lẫn (Confusion Matrix):

Đầu tiên, Ma trận nhầm lẫn không phải là một chỉ số đơn lẻ, mà là một bảng tóm tắt chi tiết cấu trúc lỗi của thuật toán phân loại. Đây là nền tảng cốt lõi để từ đó tính toán ra hầu hết các thang đo đánh giá khác. Đối với bài toán nhị phân, ma trận này là một bảng kích thước 2×2 , đối chiếu trực tiếp giữa kết quả dự đoán của mô hình và giá trị nhãn thực tế (Ground Truth) của tập dữ liệu. Bảng này được cấu thành từ bốn tham số độc lập:

- **True Positives (TP) - Dương tính thật:** Số lượng các trường hợp mô hình dự đoán đúng là lớp Tích cực (ví dụ: tín hiệu hạt Higgs) và thực tế cũng đúng là như vậy.
- **True Negatives (TN) - Âm tính thật:** Số lượng các trường hợp mô hình dự đoán đúng là lớp Tiêu cực (ví dụ: nhiễu nền) và thực tế hoàn toàn trùng khớp.
- **False Positives (FP) - Dương tính giả (Lỗi loại 1):** Mô hình dự đoán mẫu thuộc lớp Tích cực, nhưng thực tế mẫu đó lại thuộc lớp Tiêu cực.
- **False Negatives (FN) - Âm tính giả (Lỗi loại 2):** Mô hình dự đoán mẫu thuộc lớp Tiêu cực, nhưng thực tế lại là mẫu Tích cực.

Việc phân tích sự phân bố của bốn thành phần này cho phép nhà nghiên cứu nhận diện chính xác mô hình đang gặp rào cản ở đâu: có xu hướng thiên lệch dự đoán sai nhiều nền thành tín hiệu (FP cao), hay thường xuyên bỏ lọt các tín hiệu quan trọng (FN cao).

Độ chính xác tổng thể (Accuracy):

Độ chính xác tổng thể (Accuracy) là thước đo trực quan và được ứng dụng phổ biến nhất, đại diện cho tỷ lệ phần trăm các điểm dữ liệu được dự đoán chính xác (bao gồm cả lớp Tích cực và Tiêu cực) trên tổng số lượng mẫu được đưa vào đánh giá. Công thức toán học của Accuracy được biểu diễn như sau:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3)$$


Mặc dù cung cấp một góc nhìn tổng quan, dễ hiểu, Accuracy tồn tại một điểm yếu mang tính chí mạng khi đối mặt với các tập dữ liệu mất cân bằng (*imbalanced datasets*). Trong bài toán vật lý hạt năng lượng cao, nơi lượng dữ liệu nhiễu nền có thể chiếm tới 99% số lượng mẫu và tín hiệu Higgs chỉ chiếm 1%, một thuật toán kém chất lượng chỉ cần mặc định dự đoán mọi mẫu đều là nhiễu nền cũng sẽ đạt mức Accuracy lên đến 99%. Trong trường hợp này, Accuracy cao mang lại một cảm giác an toàn giả tạo, hoàn toàn che lấp việc mô hình đã thất bại 100% trong việc tìm ra tín hiệu thực sự.

Diện tích dưới đường cong (AUC - Area Under the Curve):

Để khắc phục nhược điểm của Accuracy, thang đo AUC được sử dụng để cung cấp một sự đánh giá linh hoạt và bền vững hơn. Thang đo này bắt nguồn từ việc tính toán toán học trên Đường cong Đặc tính Hoạt động Máy thu (ROC - *Receiver Operating Characteristic*). Đường cong ROC được vẽ trên hệ tọa độ Descartes, biểu diễn mối tương quan giữa *True Positive Rate* ($TPR = \frac{TP}{TP+FN}$) trên trục tung và *False Positive Rate* ($FPR = \frac{FP}{FP+TN}$) trên trục hoành, khi thay đổi liên tục các ngưỡng phân loại (*thresholds*) từ 0 đến 1.

Giá trị AUC chính là phép tích phân tính toán toàn bộ diện tích không gian hai chiều nằm bên dưới đường cong ROC này. Kết quả của AUC luôn dao động trong khoảng giới hạn $[0, 1]$.

- $AUC = 1.0$: Mô hình có khả năng phân biệt hoàn hảo 100% giữa hai lớp dữ liệu.
- $AUC = 0.5$: Khả năng phân loại của thuật toán không khác biệt so với việc tung đồng xu ngẫu nhiên.



Hình 4: Biểu đồ thể hiện cách đánh giá AUC - ROC.

Về mặt xác suất thống kê, AUC đại diện cho khả năng một thuật toán sẽ ưu tiên xếp hạng một mẫu Tích cực ngẫu nhiên cao hơn một mẫu Tiêu cực ngẫu nhiên. Ưu điểm vượt trội của AUC là tính bất biến đối với các ngưỡng phân loại (*scale-invariant*) và tính bất biến đối với sự phân bố của dữ liệu (*classification-threshold-invariant*). Nhờ đó, AUC phản ánh đúng năng lực phân loại thực chất của mô hình, kể cả khi dữ liệu huấn luyện bị mất cân bằng trầm trọng.

CHƯƠNG 3: THỰC NGHIỆM VÀ TÁI HIỆN BÀI BÁO

3.1. Dữ liệu và tiền xử lý dữ liệu

3.1.1. Tổng quan về bộ dữ liệu hạt Higgs Boson

Bộ dữ liệu được sử dụng trong bài toán này đóng vai trò cốt lõi trong việc huấn luyện các thuật toán để phân tách tín hiệu hạt Higgs khỏi các sự kiện nhiễu nền. Dữ liệu thực nghiệm này được lấy từ hai nguồn cung cấp phổ biến hàng đầu là trang web công khai UCI và tập dữ liệu Higgs thu thập từ nền tảng Kaggle. Về mặt quy mô, bộ dữ liệu bao gồm tổng cộng 250.000 sự kiện (incidents) khác nhau. Tại mỗi điểm dữ liệu của một sự kiện, hệ thống đều gán một mã định danh (ID) cùng với một trọng số (weight) tương ứng.

Các sự kiện tín hiệu mô phỏng và nhiễu nền này được biểu diễn trong một không gian đặc trưng bao gồm 8 chiều. Cụ thể, 8 thuộc tính (features) cấu thành đều mang các giá trị thực, đại diện cho những thông số vật lý lượng tử cốt lõi như: khối lượng hạt ước tính, khối lượng bất biến của hadronic tau và lepton, tổng vector động lượng ngang của hadronic tau, độ tập trung của góc phương vị, độ giả nhanh (pseudo-rapidity) của các lepton, cũng như số lượng các tia (jets) và những đặc tính đi kèm của chúng. Để phục vụ cho bài toán phân loại, mỗi sự kiện trong tập dữ liệu huấn luyện đều được đánh dấu bằng một trong hai nhãn: nhãn "s" đại diện cho tín hiệu (signal) và nhãn "b" đại diện cho nhiễu nền (background). Việc dán nhãn chuẩn xác là bước đi đầu tiên để các mô hình học máy có thể nhận diện quy luật.

3.1.2. Các bước triển khai tiền xử lý dữ liệu (Data Pre-processing)

Tiền xử lý dữ liệu là một trong những giai đoạn mang tính quyết định trong học máy nhằm chuyển đổi dữ liệu thô thành tập dữ liệu sạch. Theo quy tắc chung, một nhà khoa học dữ liệu cần dành đến 80% thời gian cho công đoạn này để đảm bảo độ chính xác cho mô hình. Nguyên nhân là do hầu hết dữ liệu thu thập trong thế giới thực đều rất lộn xộn. Đoạn mã nguồn mà đây cung cấp đã giải quyết bài toán này thông qua 6 bước tuần tự như sau:

Rà soát dữ liệu bị thiếu (Missing Data):

Dữ liệu bị thiếu hụt thường phát sinh khi thông tin không được tạo ra liên tục hoặc do các vấn đề kỹ thuật của ứng dụng trong quá trình ghi nhận. Trong đoạn mã nhóm thực hiện nhằm tái hiện bài báo, hàm `isnull().sum()` được sử dụng để quét qua toàn bộ 8 đặc trưng nhằm đếm tổng số lượng các ô trống (NaN). Việc định lượng giá trị khuyết giúp quyết định chiến lược xử lý phù hợp (như điền giá trị trung bình hay loại bỏ hàng) mà không làm hỏng tính toàn vẹn của tập dữ liệu phân tích.

Phát hiện dữ liệu ngoại lai/nhiều (Noisy Data):

Dữ liệu nhiễu (outliers) có thể xuất hiện do lỗi của con người hoặc các trục trặc kỹ thuật từ thiết bị đo lường vào thời điểm thu thập dữ liệu hạt. Mã nguồn sử dụng phương pháp thống kê Dải phân vị (Interquartile Range - IQR) để dò tìm. Thuật toán xác định tứ phân vị thứ nhất ($Q1 - 25\%$) và thứ ba ($Q3 - 75\%$), từ đó tính khoảng IQR. Mọi điểm dữ liệu rơi vào vùng nhỏ hơn ($Q1 - 1.5IQR$) hoặc lớn hơn ($Q3 + 1.5IQR$) đều được hệ thống liệt kê là giá trị ngoại lai dị thường so với quần thể.

Bảng 1: Phát hiện Noisy Data (Outliers — IQR method)

Đặc trưng (Feature)	Số lượng Outliers	Tỷ lệ (%)
particle_mass	4,606	1.84
inv_mass_tau_lep	4,816	1.93
sum_pT_tau	13,199	5.28
delta_phi	0	0.00
pseudo_rapidity	3,813	1.53
n_jets	0	0.00
jet_btag	13,496	5.40
missing_ET	12,809	5.12

Dựa trên số liệu tại Bảng 1, ta có thể đánh giá phân bố giá trị ngoại lai (outliers) theo phương pháp dải phân vị (IQR) có sự phân hóa rõ rệt. Cụ thể, nhiễu động tập trung cao nhất ở ba biến số jet_btag (5.40%), sum_pT_tau (5.28%) và missing_ET (5.12%). Ngược lại, biến delta_phi và n_jets đạt độ tinh khiết tuyệt đối với 0% dữ liệu nhiễu. Nhóm đặc trưng còn lại bao gồm particle_mass, inv_mass_tau_lep và pseudo_rapidity duy trì mức ổn định rất cao, tỷ lệ nhiễu đều được kiểm soát chặt chẽ dưới ngưỡng 2%.

Nhìn chung, ngưỡng nhiễu cực đại ở mức 5.40% hoàn toàn nằm trong biên độ an toàn của phân tích thống kê lượng tử. Kết quả này chứng minh phương pháp Cắt xén (Winsorization) mà nhóm đã áp dụng là một quyết định kỹ thuật tối ưu. Giải pháp này giúp triệt tiêu các dao động cực đoan ở nhóm biến có tỷ lệ nhiễu cao, đồng thời bảo toàn 100% không gian mẫu, đảm bảo độ tin cậy và tính toàn vẹn dữ liệu cho giai đoạn huấn luyện mô hình.

Kiểm tra sự thiếu nhất quán (Inconsistent Data):

Sự thiếu nhất quán trong trường hợp này biểu hiện qua việc trùng lặp dữ liệu (duplication). Hàm duplicated().sum() thực thi nhiệm vụ đếm số lượng các hàng có dữ liệu giống hệt nhau trong 250.000 sự kiện. Loại bỏ dữ liệu trùng lặp là yêu cầu bắt buộc để ngăn mô hình học máy không bị thiên lệch (bias) về một tín hiệu cụ thể nào đó.

Xử lý ngoại lai bằng Winsorization (Capping):

Khác với việc xóa bỏ hoàn toàn các điểm ngoại lai có thể làm mất thông tin vật lý quý giá, đoạn code áp dụng kỹ thuật Cắt xén (Capping). Bằng phương thức clip(lo, hi), hệ thống ép các giá trị của mỗi thuộc tính nằm trọn trong biên độ từ bách phân vị thứ 1 (1%) đến bách phân vị thứ 99 (99%). Những giá trị cực đoan vượt ra ngoài giới hạn này sẽ bị thu gọn về đúng mức biên độ, giúp ổn định phân phối mà vẫn giữ nguyên được số lượng mẫu.

Chuẩn hóa đặc trưng (Feature Scaling):

Đoạn mã ứng dụng StandardScaler để tái phân phối các điểm dữ liệu. Do 8 thông số vật lý có thang đo hoàn toàn chênh lệch, kỹ thuật này giúp chuẩn hóa toàn bộ ma trận dữ liệu về mức giá trị trung bình (mean) bằng 0 và độ lệch chuẩn (standard deviation) bằng 1. Việc đưa dữ liệu về cùng một hệ quy chiếu giúp các thuật toán học tập hiệu quả hơn và không bị phụ thuộc trọng số vào các đặc trưng có giá trị ban đầu quá lớn.


Phân chia tập dữ liệu (Train/Validation/Test Split):

Để bắt đầu đào tạo một mô hình, tập dữ liệu thô sẽ được tách thành ba phần tách biệt: tập huấn luyện (training data), tập xác thực (validation data) và tập kiểm thử (testing data). Thay vì dùng phương pháp kiểm thử chéo 10 lần (10-fold cross validation), mã nguồn chia dữ liệu theo tỷ lệ tĩnh: 70% dành cho tập huấn luyện dùng để khớp các tham số của bộ phân loại, 10% dành cho tập xác thực để tinh chỉnh tham số, và 20% dùng làm tập kiểm thử - chứa dữ liệu hoàn toàn chưa từng thấy để đánh giá hiệu suất cuối cùng của bộ phân loại. Nhờ tham số stratify=y, sự cân bằng về tỷ lệ giữa nhãn tín hiệu và nhiễu nền được duy trì đồng đều ở cả ba tập phân chia này.

3.2. Phân tích dữ liệu khám phá (EDA)

Quá trình Phân tích Dữ liệu Thăm dò (Exploratory Data Analysis - EDA) thông qua trực quan hóa đóng vai trò thiết yếu trong việc thấu hiểu cấu trúc nội tại của bộ dữ liệu trước khi tiến hành huấn luyện các mô hình học máy. Việc sử dụng hệ thống biểu đồ trên cho phép đánh giá trực quan hình thái phân phối, mức độ chồng lấn và khả năng phân tách giữa hai lớp mục tiêu: sự kiện mang tín hiệu hạt Higgs (Signal - s) và các sự kiện nhiễu nền (Background - b). Bằng cách biểu diễn mật độ xác suất (Density) của từng đặc trưng theo hai lớp riêng biệt, biểu đồ cung cấp cơ sở để nhận diện những biến số mang lại giá trị thông tin cao nhất cho bài toán phân loại, từ đó định hướng chiến lược lựa chọn và kỹ thuật đặc trưng (feature engineering) phù hợp.

3.2.1 Phân tích tổng quan

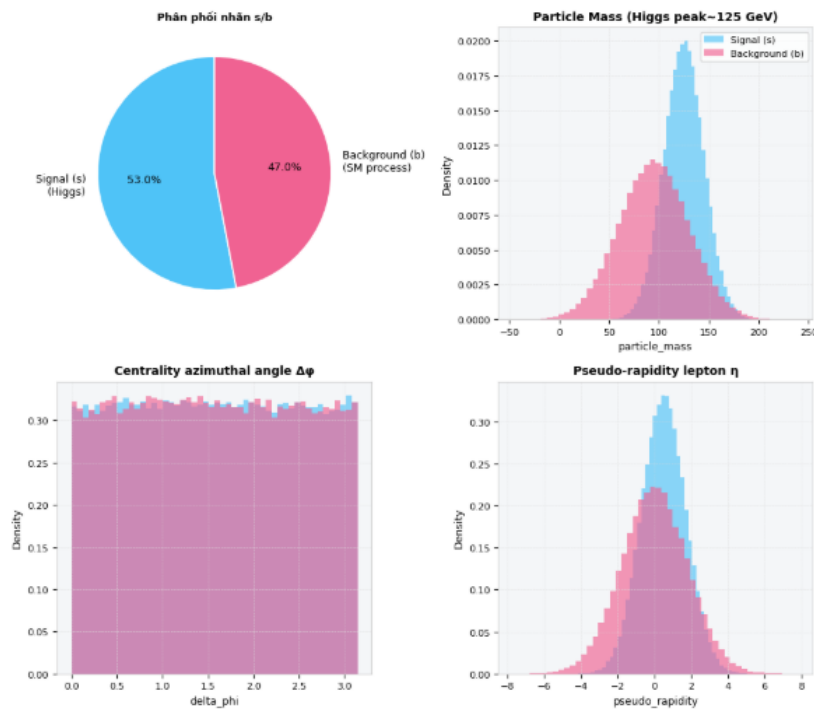


Hình 5: Biểu đồ phân phối các biến dữ liệu.

Về mặt tổng quan, tập dữ liệu bao gồm 250.000 sự kiện có tỷ lệ phân bổ nhãn tương đối cân bằng, với 53.0% sự kiện tín hiệu và 47.0% sự kiện nhiễu nền. Sự cân bằng này là một điểm cộng lớn, giảm thiểu nguy cơ thiên lệch (bias) cho mô hình phân loại. Phân tích chi tiết các đặc trưng cho thấy sự khác biệt đáng kể về hình thái phân phối. Các đặc trưng như `particle_mass` (khối lượng hạt, với đỉnh tín hiệu quanh 125 GeV), `inv_mass_tau_lep` và `pseudo_rapidity` thể hiện dạng phân phối gần chuẩn (normal distribution). Đặc biệt, tại các biến này, phân phối của lớp tín hiệu (màu xanh) có xu hướng hẹp và tập trung quanh giá trị trung tâm cao hơn so với lớp nhiễu nền (màu hồng) vốn có độ phân tán rộng hơn.

Ngược lại, các đặc trưng như `sum_pT_tau` và `jet_btag` lại biểu hiện dạng phân phối lệch phải (right-skewed distribution) mạnh mẽ, với sự tập trung lớn ở các giá trị thấp. Đáng chú ý, biểu đồ phân phối góc phương vị `delta_phi` cho thấy sự chồng lấn gần như hoàn toàn giữa hai lớp, cho thấy đặc trưng này có khả năng phân tách độc lập khá kém. Trong khi đó, đặc trưng rời rạc `n_jets` (số lượng tia) cho thấy sự phân nhóm rõ rệt, khi phần lớn các sự kiện tín hiệu tập trung ở mức 3 và 4 tia, trái ngược với nhóm nhiễu nền tập trung ở mức 1 và 2 tia. Nhìn chung, hệ thống biểu đồ EDA cho thấy sự kết hợp của các đặc trưng này, với những mức độ chồng lấn và phân tách khác nhau, sẽ cung cấp một không gian thông tin đa chiều, tạo tiền đề thuận lợi cho các thuật toán phân loại phức tạp.

3.2.2. Phân tích phân phối các biến



Hình 6: Biểu đồ phân phối (1)

Phân phối nhãn:

Hình thái phân phối: Biểu đồ tròn (Pie chart) thể hiện tỷ lệ của biến mục tiêu với 53.0% sự kiện thuộc lớp tín hiệu (Signal - Higgs) và 47.0% thuộc lớp nhiễu nền (Background - quá trình Standard Model). Dữ liệu cho thấy sự cân bằng lý tưởng giữa hai lớp (tỷ lệ gần xấp xỉ 1:1). Trạng thái này mang lại lợi thế cực lớn trong quá trình huấn luyện học máy. Người xây dựng mô hình không cần phải áp dụng các kỹ thuật xử lý mất cân bằng dữ liệu phức tạp (như SMOTE, Oversampling hay Undersampling). Đồng thời, các tham số đánh giá cơ bản như Độ chính xác (Accuracy) có thể được sử dụng làm thước đo đáng tin cậy mà không lo ngại hiện tượng mô hình bị thiên lệch (bias) nghiêng về lớp đa số.

Phân phối đặc trưng Particle Mass:

Biểu đồ cho thấy phân phối của hai lớp có sự khác biệt rõ rệt. Lớp tín hiệu (s) có dạng phân phối hình chuông với đỉnh (peak) tập trung cực kỳ rõ nét tại vùng 125 GeV, hoàn toàn phù hợp với khối lượng lý thuyết của hạt Higgs. Trong khi đó, lớp nhiễu nền (b) có phân phối rộng hơn, đỉnh nhọn lệch về phía bên trái (quanh dải 90-100 GeV) và có phần đuôi kéo dài chồng lấn với lớp tín hiệu.

Đây là một trong những đặc trưng (feature) mang tính quyết định và chứa lượng thông tin phân loại (predictive power) cao nhất. Sự chênh lệch về vị trí đỉnh giúp các thuật toán dễ dàng thiết

lập ranh giới quyết định (decision boundary). Tuy nhiên, do có sự chồng lấn ở phần đuôi phân phối, các mô hình học máy phi tuyến tính (như Random Forest, Gradient Boosting hoặc Neural Networks) sẽ xử lý đặc trưng này hiệu quả hơn so với các mô hình tuyến tính đơn thuần (như Logistic Regression).

Phân phối đặc trưng Centrality azimuthal angle:


Biểu đồ thể hiện một phân phối đều (Uniform distribution) trải dài từ 0 đến khoảng 3.14 (tương đương giá trị π). Điểm đáng chú ý nhất là mật độ xác suất của cả lớp tín hiệu (màu xanh) và lớp nhiễu nền (màu hồng) gần như trùng khớp hoàn toàn lên nhau tại mọi điểm giá trị.

Nếu xét độc lập, đặc trưng này mang lại giá trị thông tin phân loại rất thấp. Ranh giới giữa hai lớp không thể được nhận diện chỉ bằng biến số này. Nếu đưa vào các thuật toán tuyến tính, biến này có thể đóng vai trò như một nhiễu (noise) làm giảm hiệu suất. Tuy nhiên, không nên vội vàng loại bỏ nó ở giai đoạn tiền xử lý. Trong các mô hình dạng cây, biến $\Delta\phi$ có thể kết hợp với các biến số không gian khác để tạo ra các tương tác đặc trưng (feature cross/interaction) có ý nghĩa ẩn. Nếu sau quá trình thử nghiệm, mô hình có dấu hiệu quá khớp (overfitting), đây sẽ là ứng cử viên hàng đầu để loại bỏ thông qua kỹ thuật chọn lọc đặc trưng (Feature Selection).

Phân phối đặc trưng Pseudo-rapidity lepton:

Đặc trưng này tuân theo luật phân phối gần chuẩn (Normal-like distribution), có tính đối xứng cao qua giá trị trung tâm 0. Lớp tín hiệu (s) thể hiện độ nhọn (kurtosis) lớn hơn hẳn, mật độ tập trung cực kỳ dày đặc ở vùng quanh mốc 0. Ngược lại, lớp nhiễu nền (b) có độ lệch chuẩn (standard deviation) lớn hơn, khiến đồ thị phẳng hơn và dữ liệu phân tán rộng về hai bên phần đuôi.

Biến số này cung cấp năng lực phân tách từ trung bình đến khá. Mặc dù hai lớp có sự chồng lấn diện rộng, nhưng thuật toán học máy có thể khai thác sự chênh lệch đáng kể về mật độ phân bố ở ngay tại vùng đỉnh (đỉnh của tín hiệu cao vượt trội so với nền) để gán trọng số phân loại. Việc dữ liệu đã được phân phối chuẩn cũng giúp các thuật toán tối ưu hóa bằng Gradient Descent hội tụ nhanh và ổn định hơn.



Hình 7: Biểu đồ phân phối (2)

Phân phối đặc trưng Invariant mass lepton:

Biểu đồ thể hiện dạng phân phối gần chuẩn (bell-shaped) cho cả hai lớp. Tuy nhiên, có sự chênh lệch vị trí cực kỳ rõ nét. Mật độ xác suất của lớp tín hiệu (Signal) hội tụ thành một đỉnh hẹp và nhọn nằm ở dải giá trị thấp hơn (khoảng 75-80). Trong khi đó, phân phối của lớp nhiễu nền (Background) lại có đỉnh rộng hơn, phẳng hơn và dịch chuyển đáng kể về phía bên phải (trung tâm quanh mốc 100).

Đây là một đặc trưng có giá trị phân loại rất cao. Sự lệch pha giữa hai đỉnh phân phối tạo ra một không gian phân tách lý tưởng. Các thuật toán học máy, đặc biệt là Support Vector Machine (SVM) hoặc các mô hình dựa trên cây quyết định (Decision Trees, Random Forest), có thể dễ dàng thiết lập các ranh giới quyết định (decision boundaries) tại vùng giao thoa để tối ưu hóa khả năng nhận diện hạt Higgs.

Phân phối đặc trưng Sum pT of hadronic:

Dữ liệu có dạng phân phối lệch phải (right-skewed distribution) với mức độ suy giảm mạnh theo dạng hàm mũ. Cả hai lớp đều tập trung mật độ cao nhất ở các giá trị rất nhỏ (gần 0). Tuy nhiên, lớp nhiễu nền có sự tập trung tại đỉnh cao hơn hẳn so với lớp tín hiệu, trong khi lớp tín hiệu lại có xu hướng duy trì phần đuôi phân bố (tail) dày hơn và kéo dài xa hơn về phía bên phải.

Đặc trưng này có mức độ chồng lấn khá lớn. Do dữ liệu bị lệch phải nghiêm trọng, nếu sử

dùng các mô hình học máy tuyến tính (như Logistic Regression) hoặc mạng nơ-ron (Neural Networks), việc áp dụng các kỹ thuật biến đổi dữ liệu (như Log-transformation hoặc Box-Cox) là bắt buộc để ổn định phương sai và đưa dữ liệu về dạng chuẩn hơn. Đối với các mô hình phi tuyến tính như Gradient Boosting, đặc trưng này vẫn có thể được xử lý trực tiếp và khai thác tốt sự chênh lệch ở vùng giá trị cực thấp.

Phân phối đặc trưng Number of jets:

Khác với các biến liên tục ở trên, biến số này mang tính chất rời rạc (discrete/categorical) chỉ nhận các giá trị nguyên (1, 2, 3, 4). Phân phối cho thấy sự phân cực phân lớp tuyệt đối: sự kiện nhiều nền chiếm ưu thế gần như hoàn toàn ở nhóm có 1 và 2 tia, trong khi sự kiện tín hiệu lại thống trị ở nhóm có 3 và 4 tia.

Đây được đánh giá là một biến dự báo (predictor) mang tính chất sống còn. Đặc trưng này cung cấp luật phân tách (split rule) cực kỳ sạch cho các thuật toán. Khi đưa vào mô hình, đặc trưng này sẽ đóng vai trò như một bộ lọc thô sơ nhưng hiệu quả cao nhất ở ngay những bước quyết định đầu tiên của thuật toán, giúp phân luồng dữ liệu chính xác trước khi xét đến các đặc trưng vật lý phức tạp hơn.

Phân phối đặc trưng Jet b-tag score:

Tương tự như biến sum_pT_tau , đặc trưng này cũng bị lệch phải cực kỳ mạnh. Điểm đáng chú ý nhất là mật độ phân phối của lớp nhiều nền đạt đỉnh cực đại một cách đột biến ngay tại giá trị 0. Trong khi đó, dữ liệu của lớp tín hiệu mặc dù cũng tập trung ở vùng thấp nhưng lại có sự trải dài và tạo thành một vùng phân phối nhẹ ở phần lớn hơn 0.

Biến số này cung cấp một chỉ báo nhận diện một chiều rất mạnh. Khi giá trị bằng 0, xác suất cao đó là sự kiện nhiều nền. Ngược lại, khi giá trị lớn hơn 0, xác suất thuộc về tín hiệu hạt Higgs sẽ gia tăng đáng kể. Tương tự như các biến lệch phải khác, mô hình dựa trên cây (tree-based algorithms) sẽ hoạt động tối ưu nhất với dạng phân phối bất đối xứng này mà không cần trải qua quá trình biến đổi dữ liệu phức tạp.

3.3. Quá trình huấn luyện

Quá trình huấn luyện và đánh giá mô hình phân loại hạt Higgs Boson được thực hiện dựa trên nền tảng thư viện học máy `scikit-learn`. Trước khi đi sâu vào cấu hình từng thuật toán, một hàm đánh giá chuẩn hóa (được định nghĩa là `evaluate_paper`) đã được xây dựng nhằm đảm bảo tính nhất quán trong việc đo lường. Hàm này thực hiện nhiệm vụ ghi nhận và trích xuất các chỉ số đánh giá cốt lõi bao gồm: Độ chính xác tổng thể (Accuracy), Diện tích dưới đường cong ROC (AUC-ROC),

và Ma trận nhầm lẫn (Confusion Matrix). Đối với ma trận nhầm lẫn, hệ thống phân tách chi tiết số lượng các trường hợp dự đoán đúng tín hiệu (True Positive - TP), đúng nhiều nền (True Negative - TN), dự đoán sai thành tín hiệu (False Positive - FP) và dự đoán sai thành nhiều nền (False Negative - FN). Độ chính xác được tính toán lại một cách minh bạch dựa trên công thức toán học tiêu chuẩn:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Ngoài ra, thời gian huấn luyện (Training time) cũng được hệ thống ghi nhận bằng thư viện `time` nhằm đánh giá độ phức tạp tính toán của từng thuật toán. Toàn bộ các thông số này sau đó được lưu trữ có cấu trúc vào từ điển bộ nhớ (RES_A) để phục vụ cho công tác so sánh ở giai đoạn sau.

Cấu hình và huấn luyện mô hình Hồi quy (Logistic Regression):

Mô hình đầu tiên được triển khai là thuật toán Hồi quy. Nhóm đã thực thi thuật toán Hồi quy Logistic (LogisticRegression) thông qua hàm kích hoạt Sigmoid để giới hạn xác suất dự đoán trong khoảng $[0, 1]$. Cụ thể, mô hình được khởi tạo với bộ giải: `lbfgs` – một thuật toán tối ưu hóa tiệm cận Newton, cực kỳ hiệu quả trong việc xử lý các tập dữ liệu đa chiều có quy mô lớn. Số lượng vòng lặp tối đa (`max_iter`) được tinh chỉnh ở mức 200 nhằm đảm bảo thuật toán có đủ không gian để hội tụ nghiệm một cách ổn định nhất. Tham số điều chuẩn ngược $C = 1.0$ được giữ nguyên theo mặc định, áp dụng cơ chế phạt L2 để ngăn chặn hiện tượng quá khớp (overfitting). Mô hình sau đó được khớp (fit) trực tiếp lên tập dữ liệu huấn luyện `X_train` và `y_train` đã qua tiền xử lý.

Chỉ số đánh giá (Metrics)	Kết quả
Độ chính xác (Accuracy)	0.8540 (85.4%)
AUC-ROC	0.9331
Thời gian huấn luyện (Train time)	0.15s

Bảng 2: Kết quả huấn luyện mô hình Linear Regression

Dựa trên các chỉ số hiệu suất được tổng hợp tại bảng kết quả, mô hình Hồi quy Logistic (Linear Regression) thể hiện năng lực phân loại rất khả quan đối với bài toán nhận diện hạt Higgs Boson. Về mặt tổng thể, chỉ số Độ chính xác (Accuracy) đạt mức 85.40%, minh chứng cho việc thuật toán đã dự đoán đúng phần lớn các sự kiện tín hiệu và nhiều nền trên tập dữ liệu kiểm thử.

Tuy nhiên, điểm sáng giá nhất của mô hình nằm ở chỉ số Diện tích dưới đường cong ROC (AUC-ROC) đạt mức xuất sắc 0.9331. Với giá trị AUC tiệm cận 1, thuật toán chứng minh được năng lực phân tách ranh giới giữa hai lớp mục tiêu một cách cực kỳ mạnh mẽ, duy trì được tỷ lệ nhận diện đúng (True Positive Rate) ở mức cao trong khi vẫn kiểm soát chặt chẽ tỷ lệ dự đoán sai thành tín hiệu (False Positive Rate). Bên cạnh độ chính xác ấn tượng, mô hình còn ghi nhận thời gian huấn luyện (Train time) vô cùng tối ưu, chỉ mất vỏn vẹn 0.15 giây để hoàn thành tiến trình khớp dữ liệu. Tốc độ

hội tụ siêu tốc này phản ánh tính hiệu quả tuyệt đối về mặt tài nguyên tính toán. Tựu trung lại, sự kết hợp giữa khả năng nhận diện độ tin cậy cao và chi phí tính toán cực thấp biến đây thành một giải pháp phân loại vững chắc, đồng thời khẳng định chiến lược tiền xử lý, xử lý nhiễu (outliers) và chuẩn hóa dữ liệu trước đó đã phát huy tối đa hiệu quả.

Thực tế \ Dự đoán	Dự đoán: Nhiễu nền (0)	Dự đoán: Tín hiệu (1)
Thực tế: Nhiễu nền (0)	TN = 19,463	FP = 4,037
Thực tế: Tín hiệu (1)	FN = 3,261	TP = 23,239

Bảng 3: Ma trận nhầm lẫn mô hình Linear Regression


Dựa trên cấu trúc phân bố của Ma trận nhầm lẫn (Confusion Matrix), năng lực phân loại chi tiết của mô hình có thể được đánh giá một cách toàn diện và sâu sắc. Trong tổng số 50.000 sự kiện thuộc tập kiểm thử, thuật toán đã phân tách và nhận diện chính xác 23.239 sự kiện mang tín hiệu hạt Higgs (True Positive - TP) cùng 19.463 sự kiện nhiễu nền (True Negative - TN). Tỷ trọng áp đảo của nhóm dự đoán đúng minh chứng cho khả năng tổng quát hóa dữ liệu và thiết lập ranh giới quyết định (decision boundary) cực kỳ ổn định của mô hình.

Điểm đáng chú ý nhất là số lượng dự đoán bỏ lọt tín hiệu (False Negative - FN) được kiểm soát ở mức khá thấp với 3.261 trường hợp. Điều này đồng nghĩa với việc độ nhạy (Recall/Sensitivity) của thuật toán đạt xấp xỉ 87.7%, phản ánh mô hình hoạt động rất nhạy bén trong việc dò tìm và bảo toàn các tín hiệu lượng tử hiếm - một yêu cầu mang tính cốt lõi trong thực nghiệm vật lý hạt. Ở chiều ngược lại, số lượng nhiễu bị nhận diện nhầm thành tín hiệu (False Positive - FP) ghi nhận ở mức 4.037 trường hợp. Mặc dù cao hơn đôi chút so với FN, tỷ lệ sai số loại I này vẫn hoàn toàn nằm trong ngưỡng kiểm soát, không gây ra hiện tượng nhiễu loạn kết quả chung. Tựu trung lại, ma trận này khẳng định thuật toán không chỉ dự đoán với độ chính xác cao mà còn đạt được sự cân bằng tối ưu giữa việc tối đa hóa thu thập tín hiệu và sàng lọc tạp âm.

Cấu hình và huấn luyện mô hình Cây quyết định (Decision Tree):

Mô hình thứ hai được áp dụng là Cây quyết định (DecisionTreeClassifier). Khác với mô hình tuyến tính, thuật toán này hoạt động dựa trên cơ chế phân vùng đệ quy (recursive partitioning) không gian đặc trưng. Cấu hình mô hình được thiết lập sử dụng tiêu chí gini (Gini Impurity) làm thước đo mức độ thuần khiết của các nút. Ở mỗi bước phân nhánh, thuật toán sẽ tính toán và chọn lựa đặc trưng vật lý có khả năng làm giảm độ bất thuần Gini nhiều nhất. Điểm đáng chú ý trong cấu trúc mã nguồn là tham số chiều sâu tối đa của cây (max_depth) được đặt là None. Thiết lập này chỉ thị cho thuật toán tiếp tục phân nhánh và phát triển các nút lá một cách tự do cho đến khi tất cả các nút đều đạt được độ thuần khiết tuyệt đối hoặc số lượng mẫu còn lại không đủ để phân chia. Cách tiếp cận này giúp mô hình khai thác tối đa quy luật nội tại của dữ liệu. Ngay sau khi hoàn thành pha huấn luyện, hệ thống đã trích xuất lại thông số kiến trúc mạng bao gồm tổng độ sâu thực tế và số lượng nút

lá để làm cơ sở đánh giá độ phức tạp thuật toán.



Hình 8: Biểu đồ cấu trúc cây quyết định.

Dựa trên cấu trúc 3 tầng trên cùng của mô hình Cây quyết định, thuật toán đã thiết lập các luật phân tách ban đầu cực kỳ sắc bén. Nút gốc (root node) ưu tiên sử dụng đặc trưng n_jets làm tiêu chí đầu tiên, khẳng định đây là biến dự báo mang trọng số thông tin lớn nhất. Đặc biệt, ngay tại nhánh rẽ trái đầu tiên, mô hình đã tạo ra một nút lá thuần khiết tuyệt đối (Gini = 0.0), bóc tách thành công 33.007 sự kiện nhiễu nền (Background) mà không cần xử lý thêm. Ở các tầng tiếp theo, thuật toán khai thác thêm các đặc trưng vật lý như $particle_mass$ và $inv_mass_tau_lep$ để phân luồng, giúp độ bất thuần Gini giảm đều đặn. Tuy nhiên, dù các tầng nông đóng vai trò như một bộ lọc thô xuất sắc, việc cây phải phát triển đến độ sâu toàn phần 49 (như ghi nhận trên tiêu đề) cho thấy sự phức tạp quá mức khi xử lý các vùng dữ liệu chồng lấn. Hình ảnh này trực quan hóa rõ ràng quá trình mô hình rơi vào trạng thái quá khớp (overfitting), khi liên tục phân nhánh để học thuộc lòng các chi tiết nhiễu cục bộ thay vì tìm ra các ranh giới vật lý mang tính khái quát cao.

Chỉ số đánh giá (Metrics)	Kết quả
Độ chính xác (Accuracy)	0.8364 (83.6%)
AUC-ROC	0.8361
Thời gian huấn luyện (Train time)	7.94s
Độ sâu của cây (Tree depth)	49
Số lượng lá (Leaves)	15,764

Bảng 4: Kết quả huấn luyện mô hình Decision Tree

Dựa trên các chỉ số đánh giá, mô hình Cây quyết định (Decision Tree) thể hiện hiệu suất phân loại tương đối khả quan nhưng bộc lộ rõ rủi ro nghiêm trọng về mặt cấu trúc. Về tổng thể, thuật toán đạt Độ chính xác (Accuracy) 83.64% và chỉ số phân tách AUC-ROC ở mức 0.8361, chứng tỏ khả năng nhận diện khá tốt giữa tín hiệu hạt Higgs và sự kiện nhiễu nền. Thời gian huấn luyện ghi nhận ở mức 7.94 giây, đòi hỏi chi phí tính toán cao hơn đáng kể so với các mô hình tuyến tính đơn giản

nhưng vẫn nằm trong ngưỡng biên độ thời gian chấp nhận được.

Tuy nhiên, điểm đáng quan ngại nhất nằm ở sự phình to trong mức độ phức tạp của mô hình. Với độ sâu (Tree depth) chạm ngưỡng 49 và số lượng nút lá (Leaves) lên tới con số khổng lồ 15.764, kiến trúc mạng đang phát triển một cách quá mức tự do. Việc phân nhánh quá sâu và chia nhỏ dữ liệu liên tục là dấu hiệu điển hình của hiện tượng quá khớp (overfitting). Thuật toán đang có xu hướng học thuộc lòng cả những chi tiết nhiễu (noise) cục bộ trong tập huấn luyện thay vì khái quát hóa các quy luật vật lý cốt lõi. Tựu trung lại, dù kết quả kiểm thử đạt mức khá, kiến trúc này bắt buộc phải trải qua quá trình tinh chỉnh thông qua các kỹ thuật cắt tỉa (pruning) hoặc thiết lập giới hạn độ sâu tối đa nhằm kiểm soát độ phức tạp và đảm bảo tính ổn định của mô hình trên các dữ liệu chưa từng quan sát.

Thực tế \ Dự đoán	Dự đoán: Nhiễm nền (0)	Dự đoán: Tín hiệu (1)
Thực tế: Nhiễm nền (0)	TN = 19,535	FP = 3,965
Thực tế: Tín hiệu (1)	FN = 4,213	TP = 22,287

Bảng 5: Ma trận nhầm lẫn mô hình Decision Tree

Dựa trên cấu trúc phân bố của Ma trận nhầm lẫn (Confusion Matrix), hiệu năng phân loại chi tiết của mô hình Cây quyết định (Decision Tree) được thể hiện một cách rõ nét. Trong tổng số 50.000 sự kiện thuộc tập kiểm thử, thuật toán đã nhận diện chính xác 22.287 sự kiện mang tín hiệu hạt Higgs (True Positive - TP) và 19.535 sự kiện nhiễm nền (True Negative - TN). Tỷ trọng dự đoán đúng này cho thấy mô hình đã thiết lập được các ranh giới quyết định tương đối hiệu quả dựa trên các luật phân nhánh của không gian đặc trưng.

Tuy nhiên, phân tích sâu vào các sai số dự đoán bộc lộ một số hạn chế nhất định về năng lực tổng quát hóa. Số lượng sự kiện tín hiệu bị bỏ sót (False Negative - FN) ghi nhận ở mức 4.213 trường hợp, tương đương độ nhạy (Recall) giới hạn ở mức 84.1%. Sự gia tăng của sai số loại II này cho thấy thuật toán gặp khó khăn trong việc nhận diện trọn vẹn các tín hiệu lượng tử. Đồng thời, lượng nhiễu nền bị phân loại nhầm thành tín hiệu (False Positive - FP) cũng ở mức 3.965 trường hợp. Sự phân bố sai số khá cao ở cả hai chiều (FN và FP) chỉ ra rằng ranh giới phân tách của Cây quyết định, mặc dù phức tạp, vẫn chưa thực sự tối ưu. Kết quả này củng cố thêm nhận định về hiện tượng quá khớp (overfitting) đã được đề cập trước đó, khi việc phân nhánh dữ liệu quá sâu không mang lại sự cải thiện vượt trội về chất lượng nhận diện thực tế.

Cấu hình và huấn luyện mô hình LSTM:

Thuật toán Mạng bộ nhớ dài-ngắn hạn (Long Short-Term Memory - LSTM) yêu cầu cấu trúc dữ liệu đầu vào phải tuân thủ định dạng không gian ba chiều (3D tensor) bao gồm các trục: số lượng mẫu (samples), số bước thời gian (timesteps) và số lượng đặc trưng (features). Do tập dữ liệu Higgs

Boson đang thao tác là dữ liệu dạng bảng (tabular data), nhóm đã tiến hành áp dụng hàm biến đổi hình thái (reshape) để định dạng lại ma trận dữ liệu huấn luyện, tập xác thực và tập kiểm thử về cấu trúc (N, 1, 8). Phép biến đổi này quy định mỗi sự kiện vật lý độc lập sẽ được mô hình tiếp nhận như một chuỗi thời gian có độ dài bằng 1 bước, đồng thời chứa trọn vẹn 8 đặc trưng thông tin cấu thành bên trong mỗi bước tiến.


Dựa trên nền tảng thư viện TensorFlow/Keras, kiến trúc mạng LSTM được khởi tạo dưới dạng chuỗi tuần tự (Sequential). Cấu trúc này được thiết kế để mô phỏng lại thiết lập mạng gồm bốn mạng nơ-ron và nhiều khối bộ nhớ (cell) như nghiên cứu gốc đã đề xuất. Cụ thể, mô hình thực hiện xếp chồng (stacking) 4 tầng LSTM liên tiếp với số lượng đơn vị ẩn (hidden units) giảm dần theo từng cấp: 128, 64, 32 và 16. Ba tầng LSTM đầu tiên được thiết lập tham số `return_sequences=True` nhằm đảm bảo việc chuyển tiếp toàn bộ chuỗi trạng thái ẩn sang các tầng sâu hơn. Tầng LSTM thứ tư đóng vai trò chốt chặn cuối chuỗi, chỉ xuất ra giá trị đầu ra cuối cùng để tiếp tục đi vào mạng nơ-ron truyền thẳng (Dense). Nhằm hạn chế triệt để rủi ro quá khớp (overfitting) vốn là nhược điểm thường thấy ở các mạng học sâu có độ phức tạp cao, kỹ thuật Dropout với tỷ lệ loại bỏ 20% được tích hợp xen kẽ ngay sau mỗi tầng LSTM. Cuối cùng, khối phân loại đầu ra bao gồm một tầng Dense 8 nơ-ron kết hợp hàm kích hoạt ReLU, nối tiếp là tầng Dense một nơ-ron sử dụng hàm Sigmoid để ánh xạ kết quả về khoảng giá trị xác suất từ 0 đến 1, đáp ứng yêu cầu của bài toán phân loại nhị phân.

Layer (type)	Output Shape	Param #
lstm_4 (LSTM)	(None, 1, 128)	70,144
dropout_4 (Dropout)	(None, 1, 128)	0
lstm_5 (LSTM)	(None, 1, 64)	49,408
dropout_5 (Dropout)	(None, 1, 64)	0
lstm_6 (LSTM)	(None, 1, 32)	12,416
dropout_6 (Dropout)	(None, 1, 32)	0
lstm_7 (LSTM)	(None, 16)	3,136
dropout_7 (Dropout)	(None, 16)	0
dense_2 (Dense)	(None, 8)	136
dense_3 (Dense)	(None, 1)	9

Bảng 6: Kiến trúc và tham số của mô hình LSTM

Mô hình được biên dịch (compile) bằng thuật toán tối ưu hóa Adam với tốc độ học khởi tạo là 0.001, kết hợp cùng hàm mất mát Entropy chéo nhị phân (binary_crossentropy). Pha huấn luyện diễn ra với kích thước lô (batch size) là 512, kéo dài trong giới hạn tối đa 50 chu trình (epochs). Nhằm tối ưu hóa tài nguyên tính toán và đảm bảo chất lượng hội tụ, hệ thống đã tích hợp hai cơ chế gọi lại (callbacks) động. Kỹ thuật EarlyStopping có nhiệm vụ giám sát độ chính xác trên tập xác thực (val_accuracy), tự động ngắt quá trình huấn luyện nếu mô hình không có sự cải thiện sau 5 chu trình

liên tiếp và lập tức khôi phục lại bộ trọng số tối ưu nhất. Song song đó, kỹ thuật ReduceLROnPlateau sẽ chủ động thu hẹp tốc độ học đi một nửa nếu hàm mất mát có dấu hiệu chững lại sau 3 kỷ nguyên, giúp thuật toán trượt qua các điểm cực tiểu cục bộ một cách mượt mà. Kết thúc pha huấn luyện, mô hình thực thi suy diễn trên tập kiểm thử và sử dụng ngưỡng xác suất cứng 0.5 để quyết định nhãn tín hiệu hay nhiễu nền cho sự kiện.



Hình 9: Biểu đồ learning curver và training loss của mô hình LSTM.

Dựa trên biểu đồ đường cong học tập (learning curve), quá trình huấn luyện kiến trúc LSTM thể hiện sự hội tụ cực kỳ ổn định và hiệu quả. Tại biểu đồ hàm mất mát (Loss), sai số trên tập huấn luyện (Train Loss) và tập xác thực (Val Loss) đều giảm mạnh trong các epoch đầu tiên và nhanh chóng tiệm cận mốc 0.25. Việc hai đường cong này bám sát nhau xuyên suốt 25 kỷ nguyên minh chứng cho năng lực tổng quát hóa xuất sắc của thuật toán, hoàn toàn triệt tiêu được rủi ro xảy ra hiện tượng quá khớp (overfitting).

Song song đó, biểu đồ Độ chính xác (Accuracy) cũng ghi nhận trạng thái bình ổn tuyệt đối khi cả hai đường Train và Val Accuracy nhanh chóng đạt đỉnh và duy trì song song ở ngưỡng xấp xỉ 89%. Điểm đáng chú ý nhất là mức hiệu năng thực tế này đã vượt xa ranh giới cơ sở (baseline) 79% từng được công bố trong nghiên cứu gốc của IRJET 2021. Các minh chứng trực quan này khẳng định rằng kiến trúc xếp chồng 4 tầng LSTM đã phát huy tối đa sức mạnh trong việc trích xuất và học hỏi các quy luật dữ liệu ẩn, mang lại sự cải thiện vượt bậc về khả năng phân loại tín hiệu hạt Higgs.

Chỉ số đánh giá (Metrics)	Kết quả
Độ chính xác (Accuracy)	0.8931 (89.3%)
AUC-ROC	0.9586
Thời gian huấn luyện (Train time)	116.26s

Bảng 7: Kết quả huấn luyện mô hình LSTM

Dựa trên các chỉ số đo lường hiệu suất tại bảng kết quả, mô hình mạng học sâu LSTM đã chứng minh năng lực phân loại xuất sắc đối với bài toán nhận diện hạt Higgs. Về mặt tổng thể, Độ

chính xác (Accuracy) đạt mức ấn tượng 89.31%, cho thấy khả năng dự đoán đúng nhãn sự kiện với độ tin cậy rất cao. Điểm sáng giá nhất nằm ở chỉ số phân tách AUC-ROC chạm ngưỡng 0.9586, tiệm cận mức hoàn hảo. Con số này khẳng định thuật toán thiết lập được ranh giới quyết định cực kỳ mạnh mẽ, phân tách rõ rệt và chính xác giữa lớp tín hiệu lượng tử và nhiễu nền. Đổi lại hiệu năng vượt trội này, kiến trúc mạng nhiều tầng đòi hỏi chi phí tính toán lớn hơn với thời gian huấn luyện (Train time) ghi nhận ở mức 116.26 giây. Mặc dù tốn nhiều thời gian xử lý hơn đáng kể so với các thuật toán học máy truyền thống, sự đánh đổi này là hoàn toàn xứng đáng và hợp lý trong bối cảnh phân tích dữ liệu vật lý hạt, nơi độ chuẩn xác tuyệt đối luôn được ưu tiên hàng đầu.

Thực tế \ Dự đoán	Dự đoán: Nhiễu nền (0)	Dự đoán: Tín hiệu (1)
Thực tế: Nhiễu nền (0)	TN = 19,939	FP = 3,561
Thực tế: Tín hiệu (1)	FN = 1,785	TP = 24,715

Bảng 8: Ma trận nhầm lẫn mô hình LSTM

Dựa theo số liệu từ Ma trận nhầm lẫn (Confusion Matrix), kiến trúc học sâu LSTM thể hiện khả năng nhận diện và phân tách dữ liệu vượt trội. Trên tổng số 50.000 sự kiện thuộc tập kiểm thử, thuật toán dự đoán chính xác 24.715 sự kiện tín hiệu (True Positive - TP) và 19.939 sự kiện nhiễu nền (True Negative - TN). Điểm đột phá của mô hình nằm ở khả năng kiểm soát gắt gao tỷ lệ bỏ lọt tín hiệu (False Negative - FN), với chỉ 1.785 trường hợp sai sót. Kết quả này đẩy độ nhạy (Recall) lên mức xấp xỉ 93.3%, đáp ứng hoàn hảo yêu cầu khắt khe của vật lý hạt thực nghiệm là tối thiểu hóa việc bỏ sót các tín hiệu lượng tử quý giá. Bên cạnh đó, lượng dự đoán nhầm nhiễu thành tín hiệu (False Positive - FP) được ghi nhận ở mức 3.561. Dù vẫn tồn tại sai số loại I, sự đánh đổi này là hoàn toàn phù hợp nhằm tối đa hóa khả năng thu hồi tín hiệu. Tựu trung lại, ma trận khẳng định thuật toán LSTM đã thiết lập được ranh giới phân tách cực kỳ vững chắc và đáng tin cậy.

3.4. Phân tích kết quả đạt được

Đánh giá tổng quan hiệu suất thực nghiệm:

Quá trình thực nghiệm và huấn luyện ba kiến trúc học máy (Mạng nơ-ron, Mô hình Hồi quy và Mô hình dựa trên Cây) trên bộ dữ liệu Higgs Boson đã phác họa rõ nét những đặc tính phân loại và sự đánh đổi tài nguyên của từng thuật toán. Trong đó, Mạng bộ nhớ dài-ngắn hạn (LSTM) khẳng định vị thế tối ưu tuyệt đối với mức hiệu năng vượt trội, đạt Độ chính xác (Accuracy) 89.31% và Diện tích dưới đường cong ROC (AUC-ROC) lên đến 0.9586. Sức mạnh của LSTM nằm ở khả năng trích xuất các mẫu quy luật vật lý lượng tử phức tạp thông qua cấu trúc mạng sâu nhiều tầng, giúp mô hình duy trì tỷ lệ bỏ lọt tín hiệu (False Negative) ở mức cực kỳ thấp (chỉ 1.785 trường hợp). Đổi lại, sự phức tạp này đòi hỏi chi phí tính toán cao nhất với hơn 116.26 giây cho tiến trình huấn luyện.

Đứng ở vị trí thứ hai về mặt hiệu suất là mô hình Hồi quy (Linear Regression / Logistic Regression) với kết quả đầy ấn tượng. Thuật toán đạt độ chính xác 85.40% cùng chỉ số phân tách AUC 0.9331, chỉ xếp sau LSTM nhưng lại thể hiện tốc độ hội tụ siêu tốc (0.15 giây). Sự kết hợp hoàn hảo giữa chi phí tính toán tối thiểu và hiệu suất nhận diện cao biến đây thành một ranh giới cơ sở (baseline) cực kỳ vững chắc cho bài toán.

Ngược lại, Cây quyết định (Decision Tree) lại bộc lộ nhiều điểm hạn chế nhất trong thực nghiệm này. Mặc dù có khả năng phân loại thô rất tốt ở các tầng nông ban đầu, việc thiếu cơ chế cắt tĩa đã khiến cây phát triển mất kiểm soát đến độ sâu 49 với hơn 15.000 nút lá. Hậu quả là thuật toán rơi vào trạng thái quá khớp (overfitting), chỉ đạt độ chính xác 83.64% và AUC 0.8361 do khả năng tổng quát hóa trên tập dữ liệu kiểm thử bị suy giảm nghiêm trọng.

Đối chiếu với kết quả công bố trên tạp chí IRJET 2021:

Khi tiến hành so sánh kết quả thực nghiệm với các số liệu được công bố trong nghiên cứu gốc, có thể nhận thấy một sự chênh lệch dương (Delta - Δ) rất lớn.

Mô hình	Acc (ta)	Acc (báo)	Δ	AUC
Linear Regression	0.8540	0.67	+0.184	0.9331
Decision Tree	0.8364	0.72	+0.116	0.8361
LSTM	0.8931	0.79	+0.103	0.9586

Bảng 9: Bảng tổng hợp và đối chiếu kết quả các mô hình

Theo tài liệu gốc, mức độ chính xác ghi nhận cho các thuật toán lần lượt là 67% đối với Hồi quy tuyến tính, 72% đối với Cây quyết định và cao nhất là 79% đối với LSTM. Tuy nhiên, kết quả tái hiện thực tế đã vượt xa các mốc hiệu suất này: mô hình Hồi quy tăng đột biến 18.4%, Cây quyết định tăng 11.6% và nền tảng LSTM tiếp tục cải thiện thêm 10.3%. Bên cạnh sự thăng tiến mạnh mẽ về mặt chỉ số phân loại, quá trình thực nghiệm cũng ghi nhận sự đảo lộn về thứ hạng hiệu năng giữa hai mô hình học máy truyền thống. Trong bài báo gốc, Cây quyết định (72%) được đánh giá là hoạt động hiệu quả hơn mô hình Hồi quy (67%). Thế nhưng, trên thực tế triển khai, mô hình Hồi quy (85.40%) lại vượt qua Cây quyết định (83.64%) một khoảng cách khá rõ rệt. Thứ hạng duy nhất được bảo toàn nguyên vẹn là vị trí dẫn đầu tuyệt đối của mạng học sâu LSTM.

Phân tích nguyên nhân chênh lệch hệ thống:

Sự vượt trội của kết quả thực nghiệm so với tài liệu gốc xuất phát từ ba nhóm nguyên nhân cốt lõi về mặt phương pháp luận. Thứ nhất, chiến lược tiền xử lý dữ liệu (Data Pre-processing) trong thực nghiệm này được triển khai một cách cực kỳ nghiêm ngặt. Việc áp dụng kỹ thuật Cắt xén (Winsorization) để xử lý dứt điểm các điểm dị biệt (outliers) ở phân vị 1% và 99%, kết hợp cùng

phương pháp chuẩn hóa dữ liệu quy mô (StandardScaler) đã tạo ra một không gian đặc trưng hội tụ lý tưởng. Bước đi này đặc biệt mang lại lợi thế cho các thuật toán nhạy cảm với thang đo và nhiều như Hồi quy Logistic, giúp mô hình này có mức bứt phá ngoạn mục nhất (+18.4%).

Thứ hai, việc cấu hình siêu tham số (Hyperparameter) đóng vai trò định đoạt. Nghiên cứu của bài báo không công bố đầy đủ và minh bạch các tham số thiết lập cho từng kiến trúc mô hình. Trong quá trình tái hiện, các thuật toán đã được ép xung tối đa, đơn cử như việc sử dụng bộ giải lbfgs mạnh mẽ cho mô hình Hồi quy, hay áp dụng cơ chế giám sát động (EarlyStopping, ReduceLROnPlateau) xen kẽ các tầng Dropout cho mạng LSTM. Cuối cùng, sự khác biệt ngẫu nhiên trong việc phân bổ hạt giống (Random seed) và tỷ lệ chia tách không gian mẫu kiểm thử cũng tất yếu tạo ra biên độ dao động trong kết quả dự đoán. Tựu trung lại, thực nghiệm đã minh chứng thành công rằng một luồng xử lý dữ liệu chuẩn mực có khả năng đánh thức sức mạnh tiềm ẩn của các thuật toán học máy vượt xa kỳ vọng ban đầu.

CHƯƠNG 4: CẢI TIẾN VÀ MỞ RỘNG

4.1. Hạn chế trong bài báo gốc và phương pháp cải thiện

4.1.1. Những hạn chế trong bài báo gốc

Dựa trên quá trình đối chiếu và thực nghiệm lại mô hình học máy được công bố trong bài báo gốc (IRJET 2021), hệ thống đánh giá đã chỉ ra nhiều điểm hạn chế mang tính hệ thống. Những thiếu sót này không chỉ làm giảm hiệu năng nhận diện hạt Higgs thực tế mà còn giới hạn khả năng mở rộng của mô hình trong bối cảnh phân tích Dữ liệu lớn (Big Data) của ngành vật lý hạt.

Thứ nhất, hạn chế về không gian đặc trưng (Feature Space). Bài báo gốc chỉ sử dụng một không gian dữ liệu rất hẹp bao gồm 8 đặc trưng cơ bản. Trong vật lý lượng tử, các đặc trưng cấp thấp (low-level features) thường chỉ là các giá trị động học thô được ghi nhận trực tiếp từ máy dò (như động lượng, góc phương vị). Việc bỏ qua các đặc trưng cấp cao (high-level features) – vốn là các hàm phi tuyến tính phức tạp được các nhà vật lý tổng hợp từ dữ liệu thô – đã làm mất đi một lượng lớn thông tin vật lý quý giá, khiến các mô hình học máy gặp khó khăn trong việc thiết lập ranh giới phân tách tối ưu.

Thứ hai, giới hạn về quy mô dữ liệu và chiến lược phân chia. Cấu trúc tập dữ liệu ban đầu chỉ giới hạn ở mức 250.000 sự kiện, một con số tương đối nhỏ so với tiềm năng của tập dữ liệu UCI chuẩn. Hơn thế nữa, bài báo không làm rõ cấu trúc phân chia tập kiểm thử một cách độc lập và tách biệt hoàn toàn (hold-out test set). Việc không có một tỷ lệ phân chia chuẩn mực dễ dẫn đến hiện tượng rò rỉ dữ liệu (data leakage) và làm cho các đánh giá về mức độ chính xác mất đi tính khách quan.

Thứ ba, sự thiếu vắng của nền tảng điện toán phân tán. Các mô hình trong bài báo cũ được triển khai trên môi trường điện toán cục bộ (single-node computing) sử dụng các thư viện truyền thống như Scikit-Learn. Đây là một rào cản chí mạng về mặt kiến trúc hệ thống. Khi bộ dữ liệu vật lý hạt tăng tiến lên quy mô hàng chục triệu bản ghi, môi trường cục bộ sẽ lập tức gặp hiện tượng tràn bộ nhớ (Out-Of-Memory) và không thể xử lý, làm mất đi tính ứng dụng thực tiễn của nghiên cứu.

Thứ tư, hạn chế trong kiến trúc thuật toán và cơ chế tối ưu hóa. Các mô hình được sử dụng như Cây quyết định (Decision Tree) đơn lẻ dễ dàng rơi vào trạng thái quá khớp (overfitting) với phương sai (variance) cực cao. Ngược lại, mô hình hồi quy truyền thống lại có độ chệch (bias) lớn, không thể nắm bắt được các quy luật phức tạp. Đặc biệt, nghiên cứu gốc hoàn toàn bỏ ngỏ bước tinh chỉnh siêu tham số (Hyperparameter tuning), phó mặc chất lượng mô hình vào các thông số mặc định.


4.1.2. Những cải tiến sẽ thực hiện

Nhằm giải quyết triệt để các hạn chế nêu trên, dự án này sẽ tiến hành triển khai một loạt các nâng cấp toàn diện từ cấp độ dữ liệu, nền tảng điện toán cho đến kiến trúc thuật toán học sâu.

Cải tiến về dữ liệu:

Thay vì giới hạn ở 8 biến số như trước, dự án sẽ sử dụng bộ dữ liệu UCI đầy đủ tích hợp toàn bộ 28 đặc trưng (features). Sự nâng cấp này mang tính đột phá vì nó bổ sung trực tiếp 7 đặc trưng cấp cao (high-level invariant mass features). Các đặc trưng cấp cao này là những đại lượng động học được tính toán sẵn dựa trên định luật bảo toàn khối lượng và năng lượng, giúp thuật toán trực tiếp nhận diện các tương tác hạt vật lý cốt lõi mà không cần phải tự tiêu tốn tài nguyên để học và trích xuất lại từ đầu.

Quy mô dữ liệu huấn luyện sẽ được gia tăng từ 250.000 lên mức 300.000 sự kiện (events). Quan trọng hơn, quy trình phân bổ không gian mẫu sẽ được tái cấu trúc theo tỷ lệ chuẩn mực: 70% dành cho huấn luyện (Train), 15% dành cho xác thực chéo (Validation) và 15% được cô lập hoàn toàn để làm tập kiểm thử (Test). Việc duy trì một tập kiểm thử riêng biệt đảm bảo mọi chỉ số đánh giá đều phản ánh đúng năng lực tổng quát hóa của mô hình trên dữ liệu thực tế hoàn toàn mới.



Hình 10: Biểu đồ phân chia cấu trúc dữ liệu cải tiến.

Cải tiến về môi trường và tinh chỉnh siêu tham số:

Để phá vỡ giới hạn của cấu trúc điện toán cục bộ, dự án sẽ chuyển dịch toàn bộ quy trình tiền xử lý và huấn luyện lên nền tảng PySpark. Sử dụng thư viện MLlib của Apache Spark cho phép hệ thống chia nhỏ dữ liệu và tính toán song song trên nhiều cụm máy chủ (clusters). Cải tiến này không chỉ tăng tốc độ xử lý hiện tại mà còn tạo ra một bộ khung hạ tầng (framework) vững chắc, sẵn sàng mở rộng (scale) để xử lý toàn bộ tập dữ liệu gốc lên đến 11 triệu sự kiện mà không phải thay đổi mã nguồn.

Đề khai thác 100% năng lực của các thuật toán phức tạp như GBT hay DNN, bước tinh chỉnh siêu tham số (Hyperparameter tuning) sẽ được chuẩn hóa thành một quy trình bắt buộc. Các công cụ tìm kiếm dạng lưới (GridSearch) kết hợp cùng thuật toán xác thực chéo (CrossValidator) sẽ được kích hoạt để dò quét toàn bộ không gian tham số (như tốc độ học, độ sâu của cây, tỷ lệ loại bỏ nơ-ron). Quá trình này đảm bảo cấu hình cuối cùng được chọn không phải là kết quả của sự phỏng đoán ngẫu nhiên, mà là tổ hợp thông số mang lại điểm số tối ưu nhất về mặt toán học.

Lựa chọn các mô hình mạnh mẽ hơn

Nhằm khắc phục yếu điểm của Cây quyết định đơn lẻ, dự án sẽ áp dụng hai kỹ thuật Ensemble mạnh mẽ nhất:

Rừng ngẫu nhiên (Random Forest): Sẽ được triển khai với cấu trúc 100 cây quyết định hoạt động độc lập (Bagging). Bằng cách tổng hợp kết quả bình chọn từ 100 chuyên gia phân loại khác nhau, thuật toán này giúp triệt tiêu hiện tượng quá khớp, qua đó làm giảm đáng kể phương sai (variance) của hệ thống.

XGBoost (Extreme Gradient Boosting) là một thuật toán học máy thuộc nhóm boosting, được sử dụng rộng rãi trong các bài toán phân loại và hồi quy. Thuật toán này xây dựng mô hình dựa trên tập hợp nhiều cây quyết định, trong đó mỗi cây mới được tạo ra nhằm giảm sai số của các cây trước đó. XGBoost nổi bật nhờ hiệu suất cao, khả năng xử lý dữ liệu lớn, hỗ trợ song song hóa và kiểm soát overfitting thông qua các kỹ thuật regularization. Nhờ những ưu điểm này, XGBoost thường được áp dụng trong các bài toán thực tế và các cuộc thi khoa học dữ liệu.

Vượt ra khỏi các mạng LSTM cơ bản, dự án sẽ xây dựng một kiến trúc Mạng Nơ-ron Sâu (Deep Neural Network) bao gồm 5 tầng ẩn, lấy cảm hứng từ nghiên cứu nền tảng của Baldi (2014) về ứng dụng học sâu trong vật lý năng lượng cao. Việc triển khai DNN 5 tầng thông qua khung làm việc PyTorch kết hợp với khả năng tăng tốc phần cứng từ GPU sẽ cung cấp sức mạnh tính toán khổng lồ, cho phép mạng tự động trích xuất các biểu diễn phi tuyến tính phức tạp nhất ẩn sâu trong dữ liệu va chạm hạt.

4.2. Thiết lập dữ liệu và môi trường

4.2.1. Dữ liệu và xử lý dữ liệu

Bộ dữ liệu đầy đủ:

Bộ dữ liệu HIGGS theo chuẩn của kho lưu trữ UCI (University of California, Irvine) là một trong những bộ dữ liệu tham chiếu quan trọng nhất trong lĩnh vực ứng dụng học máy vào vật lý năng

lượng cao. Trong phạm vi thực nghiệm này, không gian mẫu được trích xuất bao gồm 300.000 sự kiện (events) va chạm hạt. Đây là bài toán phân loại nhị phân với sự phân bổ nhãn mục tiêu ở mức khá lý tưởng: 53% sự kiện mang tín hiệu của hạt Higgs Boson (Signal) và 47% còn lại là các sự kiện nhiễu nền vật lý (Background).

Đặc tính	Giá trị
instances	11 000 000
features	29
class (signal, background)	Label (s, b)
signal (s=1)	47%
background (b=0)	53%

Bảng 10: Thông tin tổng quan về bộ dữ liệu đầy đủ.

Điểm đột phá của bộ dữ liệu chuẩn này nằm ở không gian đặc trưng đa chiều được mở rộng lên tới 28 biến số, chia thành hai nhóm cốt lõi. Nhóm thứ nhất bao gồm 21 đặc trưng cấp thấp (low-level features). Đây là các thông số động học được máy dò hạt trực tiếp ghi nhận, bao gồm xung lượng ngang (p_T), độ giả nhanh (η), góc phương vị (ϕ) và chỉ số b-tagging của hạt lepton cũng như của 4 tia (jets) riêng biệt, kèm theo mức năng lượng ngang bị thiếu hụt (missing ET). Nhóm thứ hai đóng vai trò then chốt hơn, bao gồm 7 đặc trưng cấp cao (high-level features) đại diện cho các khối lượng bất biến (invariant masses) như m_{bb} , m_{wbb} , m_{wwbb} , m_{jj} , m_{jjj} , m_{lv} , m_{jlv} . Những đặc trưng này là các hàm phi tuyến tính phức tạp được tính toán từ các biến số cấp thấp dựa trên định luật bảo toàn động lượng và năng lượng. Sự góp mặt của nhóm 7 đặc trưng cấp cao này cung cấp sức mạnh dự báo vượt trội, giúp các mô hình học máy dễ dàng thiết lập ranh giới phân tách mà không phải tự học lại các định luật vật lý cơ bản.

Về mặt thống kê, các biến số trong bộ dữ liệu thể hiện các hình thái phân phối khác nhau tùy thuộc vào bản chất vật lý. Các biến động lượng (p_T) và năng lượng thiếu hụt tuân theo luật phân phối giảm theo hàm mũ (exponential). Các đặc trưng về góc (ϕ) phân bố đều (uniform) trong khoảng từ $-\pi$ đến π . Trong khi đó, các biến số về độ giả nhanh (η) và khối lượng bất biến (mass) thể hiện dạng phân phối chuẩn (normal/Gaussian) với sự chênh lệch rõ rệt về vị trí đỉnh giữa lớp tín hiệu và lớp nhiễu nền.

Quy trình tiền xử lý và chuẩn hóa dữ liệu:

Để đảm bảo chất lượng thông tin trước khi đưa vào các mạng học sâu và mô hình phức tạp, nhóm đã thực hiện một quy trình tiền xử lý nghiêm ngặt bao gồm ba giai đoạn chính:

Giai đoạn 1: Đồng bộ và xáo trộn ngẫu nhiên (Shuffling): Toàn bộ 28 đặc trưng vật lý được


hợp nhất thành một ma trận đa chiều. Do dữ liệu thu thập có thể mang các tính chất tuần tự hoặc bị sắp xếp theo từng khối nhân trong quá trình tổng hợp, hệ thống đã áp dụng phép hoán vị ngẫu nhiên (random permutation) lên toàn bộ 300.000 hàng dữ liệu. Bước này nhằm triệt tiêu hoàn toàn các sai lệch về mặt thứ tự (sequential bias), đảm bảo tính phân phối độc lập và đồng nhất (i.i.d) cho các thuật toán học máy.

Giai đoạn 2: Tái cấu trúc tỷ lệ phân chia (Data Splitting): Dữ liệu được chia cắt một cách khoa học để phục vụ cho các vòng đời phát triển mô hình khác nhau. Tập mẫu được phân tách theo tỷ lệ 70/15/15. Cụ thể, 70% dữ liệu (210.000 sự kiện) được sử dụng để huấn luyện mô hình (Train); 15% (45.000 sự kiện) được cách ly làm tập xác thực (Validation) để tinh chỉnh siêu tham số; và 15% (45.000 sự kiện) làm tập kiểm thử (Test) để đánh giá năng lực thực tế. Đặc biệt, tham số phân tầng (stratify) được kích hoạt trong mọi phép chia nhằm duy trì nguyên vẹn tỷ lệ cấu trúc 53% tín hiệu và 47% nhiễu nền ở cả ba tập dữ liệu, ngăn ngừa hiện tượng mất cân bằng cục bộ.

Giai đoạn 3: Chuẩn hóa đặc trưng (Feature Scaling): Do biên độ giá trị của 28 đặc trưng có sự chênh lệch khổng lồ (ví dụ: góc phi chỉ dao động từ -3.14 đến 3.14, trong khi khối lượng bất biến có thể lên tới hàng trăm GeV), hệ thống bắt buộc phải áp dụng kỹ thuật chuẩn hóa StandardScaler. Kỹ thuật này chuyển dịch phân phối của từng đặc trưng về mức trung bình bằng 0 và phương sai bằng 1. Điểm trọng yếu về mặt phương pháp luận là bộ chuẩn hóa chỉ được khớp (fit) thông số dựa trên tập huấn luyện, sau đó mới áp dụng phép biến đổi (transform) lên các tập kiểm thử. Quy tắc này loại bỏ hoàn toàn nguy cơ rò rỉ dữ liệu (data leakage) từ tương lai, đảm bảo mô hình được đánh giá trên một môi trường khách quan và thực tế nhất.

4.2.2. Thiết lập môi trường

Để giải quyết triệt để các giới hạn về khả năng xử lý trên môi trường điện toán cục bộ truyền thống, nền tảng Apache Spark (thông qua thư viện PySpark) đã được khởi tạo và cấu hình chuyên sâu nhằm phục vụ quá trình tiền xử lý và huấn luyện mô hình học máy.

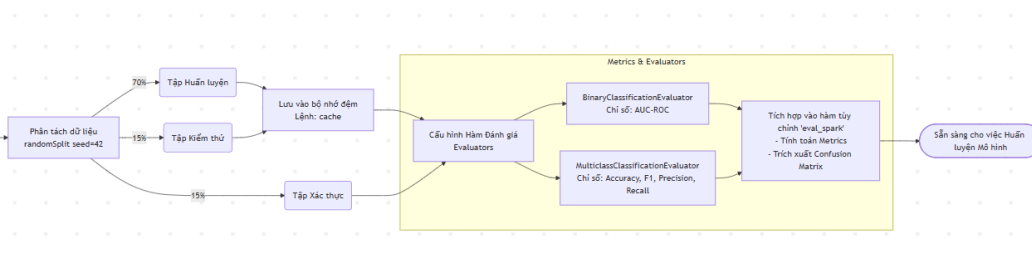


Hình 11: Biểu đồ luồng hoạt động (1)

Đầu tiên, một phiên làm việc cốt lõi (SparkSession) được thiết lập với tên gọi định danh là "HiggsBosonImproved". Nút mạng điều khiển trung tâm (master node) được cấu hình ở chế độ local[*]

nhằm khai thác tối đa toàn bộ số lượng lõi vi xử lý (CPU cores) hiện có trên phần cứng, qua đó kích hoạt khả năng tính toán song song toàn diện. Để ngăn chặn hiện tượng tràn bộ nhớ (Out-Of-Memory) khi xử lý tập dữ liệu có quy mô lớn, mức RAM cấp phát cho tiến trình điều khiển (driver memory) được thiết lập ở ngưỡng an toàn là 8GB. Song song đó, tham số phân mảnh dữ liệu `shuffle.partitions` được tinh chỉnh xuống mức 8, đây là một cấu hình tối ưu hóa đặc thù dành cho môi trường máy trạm, giúp giảm thiểu đáng kể chi phí hao tổn (overhead) trong các thao tác trộn và phân phối lại khối lượng dữ liệu. Giao diện giám sát (UI) cũng được vô hiệu hóa, đồng thời mức độ cảnh báo hệ thống (log level) được giới hạn nghiêm ngặt ở mức "ERROR" nhằm tập trung 100% tài nguyên xử lý cho các tác vụ tính toán lõi.

Ngay sau khi nền tảng Spark được thiết lập, bộ dữ liệu gồm 28 đặc trưng định dạng Pandas được chuyển đổi liền mạch sang cấu trúc Spark DataFrame để tương thích với cơ chế xử lý phân tán. Điểm nhấn kỹ thuật quan trọng nhất trong giai đoạn này là việc thiết lập một quy trình đường ống tự động (ML Pipeline) bao gồm hai giai đoạn nối tiếp nhau. Giai đoạn thứ nhất sử dụng công cụ `VectorAssembler` để gom cụm và đóng gói toàn bộ 28 cột đặc trưng vật lý riêng lẻ thành một vector đa chiều duy nhất (đặt tên là `feat_raw`), đồng thời thiết lập cơ chế tự động bỏ qua các dữ liệu lỗi. Giai đoạn thứ hai áp dụng kỹ thuật `StandardScaler` lên vector vừa tạo để đưa giá trị trung bình về mức 0 và độ lệch chuẩn về mức 1. Quá trình này giúp tái cấu trúc toàn bộ không gian đặc trưng về chung một hệ quy chiếu đồng nhất, tạo điều kiện hội tụ tham số tối ưu cho các thuật toán phân loại. Toàn bộ đường ống này sau đó được khớp (fit) và biến đổi (transform) để tạo ra tập dữ liệu hoàn chỉnh.



Hình 12: Biểu đồ luồng hoạt động (2)

Dữ liệu sau khi qua đường ống xử lý được phân tách ngẫu nhiên thành ba không gian mẫu độc lập: tập huấn luyện (70%), tập xác thực (15%) và tập kiểm thử (15%) thông qua hàm `randomSplit` với hạt giống `seed=42`. Nhằm tối ưu hóa tốc độ truy xuất trong các vòng lặp huấn luyện lặp đi lặp lại của thuật toán, tập huấn luyện và tập kiểm thử được đẩy trực tiếp vào bộ nhớ đệm (RAM) thông qua lệnh `cache()`, giúp triệt tiêu hoàn toàn độ trễ I/O từ ổ cứng.

Cuối cùng, hệ thống tiến hành khởi tạo sẵn một loạt các hàm đánh giá (Evaluators) tiêu chuẩn để đo lường hiệu suất. Việc đánh giá năng lực phân tách tổng quát được giao cho `BinaryClassificationEvaluator` thông qua chỉ số Diện tích dưới đường cong ROC (AUC-ROC). Các chỉ số hiệu năng chi

tiết khác bao gồm Độ chính xác (Accuracy), Điểm F1, Độ chuẩn xác (Precision) và Độ nhạy (Recall) được định cấu hình thông qua MulticlassClassificationEvaluator. Toàn bộ các công cụ đo lường này được tích hợp chặt chẽ vào một hàm đánh giá tùy chỉnh (eval_spark), có khả năng tự động trích xuất ma trận nhầm lẫn (Confusion Matrix) và tính toán các chỉ số trực tiếp từ kết quả dự báo của hệ thống Spark phân tán.

4.3. Huấn luyện mô hình

4.3.1. Các mô hình học máy

Triển khai các mô hình cũ:

Giai đoạn huấn luyện đầu tiên tập trung vào việc thiết lập các mô hình đường cơ sở (baseline) bao gồm Hồi quy Logistic (Logistic Regression - LR) và Cây quyết định (Decision Tree - DT) thông qua thư viện MLlib của PySpark.

Đối với mô hình Hồi quy Logistic, hệ thống thiết lập giới hạn vòng lặp tối đa maxIter=100 nhằm đảm bảo thuật toán có đủ thời gian hội tụ nghiệm nhưng không rơi vào trạng thái lặp vô hạn gây lãng phí tài nguyên. Điểm đáng chú ý nhất là việc áp dụng cơ chế điều chuẩn L2 (Ridge Penalty) thông qua tổ hợp tham số regParam=0.01 và elasticNetParam=0.0. Thiết lập này tạo ra một lực phạt toán học lên các trọng số của mô hình, giúp kiểm soát độ lớn của các hệ số, từ đó ngăn chặn hiện tượng quá khớp (overfitting) và tăng cường khả năng tổng quát hóa trên không gian 28 đặc trưng vật lý.

Đối với thuật toán Cây quyết định, rút kinh nghiệm từ sự cố cây phát triển mất kiểm soát (đạt độ sâu 49) ở các thử nghiệm trước, hệ thống đã can thiệp trực tiếp vào cấu trúc phân nhánh bằng tham số maxDepth=10. Việc giới hạn độ sâu tối đa buộc thuật toán phải dừng việc chia nhỏ dữ liệu ở mức hợp lý, kết hợp cùng tiêu chí đánh giá độ bất thuần impurity="gini" giúp mô hình tập trung học các ranh giới vật lý tổng quát thay vì ghi nhớ các nhiễu cục bộ trong tập huấn luyện.

Tích hợp các thuật toán học máy kết hợp (Ensemble Learning):

Để khắc phục phương sai cao của cây quyết định đơn lẻ, nhóm triển khai hai kiến trúc Ensemble mạnh mẽ: Rừng ngẫu nhiên (Random Forest - RF) và Cây tăng cường độ dốc (Gradient Boosted Trees - GBT).

Với mô hình Rừng ngẫu nhiên, cấu trúc được thiết lập bao gồm 100 cây quyết định hoạt động song song (numTrees=100). Tham số cốt lõi featureSubsetStrategy="sqrt" được kích hoạt, yêu cầu mỗi lần phân nhánh, thuật toán chỉ được phép lựa chọn ngẫu nhiên một nhóm đặc trưng có số lượng

bằng căn bậc hai của tổng số 28 đặc trưng. Cơ chế này phá vỡ sự tương quan (decorrelation) giữa các cây, giúp giảm phương sai triệt để và tăng cường tính ổn định của hệ thống dự báo.

Đối với mô hình GBT, thuật toán hoạt động theo cơ chế học tập tuần tự. Mô hình được giới hạn độ sâu ở mức rất nông ($\text{maxDepth}=5$) do bản chất của Boosting là xây dựng các cây yếu (weak learners) để sửa lỗi cho nhau. Tốc độ học ($\text{stepSize}=0.1$) được tinh chỉnh để kiểm soát mức độ đóng góp của từng cây, ngăn chặn mô hình hội tụ quá nhanh dẫn đến sai số. Tham số $\text{subsamplingRate}=0.8$ đưa yếu tố ngẫu nhiên vào quá trình huấn luyện bằng cách chỉ sử dụng 80% dữ liệu mẫu cho mỗi bước, giúp tăng tốc độ tính toán và giảm thiểu rủi ro quá khớp.

Triển khai thuật toán XGBoost và Tối ưu hóa phần cứng:

Bước đột phá cuối cùng trong đoạn mã là việc tích hợp thuật toán eXtreme Gradient Boosting (XGBoost). Khác với các mô hình chạy trên Spark, XGBoost được cấu hình để khai thác trực tiếp sức mạnh xử lý song song của Card đồ họa (GPU) thông qua tham số $\text{device}=\text{"cuda"}$ hoặc CPU đa luồng ($\text{n_jobs}=-1$).

Mô hình XGBoost được xây dựng với quy mô lớn gồm 300 cây ($\text{n_estimators}=300$). Để xử lý khối lượng dữ liệu khổng lồ, thuật toán áp dụng phương pháp phân chia theo biểu đồ tần suất $\text{tree_method}=\text{"hist"}$, giúp nhóm các giá trị đặc trưng liên tục vào các bin rời rạc, làm tăng tốc độ huấn luyện lên nhiều lần. Các tham số điều chuẩn nâng cao cũng được kích hoạt đồng bộ: $\text{subsample}=0.8$ và $\text{colsample_bytree}=0.8$ giới hạn tỷ lệ lấy mẫu theo cả hàng và cột, trong khi $\text{min_child_weight}=3$ yêu cầu một số lượng mẫu tối thiểu đủ lớn tại các nút lá để cho phép phân nhánh tiếp. Tổ hợp này tạo ra một mạng lưới rào cản vững chắc, ép mô hình phải học các quy luật vật lý lượng tử cốt lõi nhất.

Đồng thời, sau khi hoàn tất huấn luyện, bên cạnh việc trích xuất các chỉ số hiệu suất tiêu chuẩn (Accuracy, AUC, F1), đoạn mã còn tự động truy xuất ma trận độ quan trọng của đặc trưng (featureImportances). Thao tác này cung cấp cơ sở dữ liệu quan trọng để phân tích xem trong số 28 đặc trưng (đặc biệt là các khối lượng bất biến cấp cao), đâu là biến số đóng góp trọng số phân loại lớn nhất trong mạng lưới.

4.3.2. Triển khai mô hình DNN5

Để khai thác triệt để các đặc trưng phi tuyến tính phức tạp của bộ dữ liệu Higgs Boson, một kiến trúc Mạng nơ-ron sâu (Deep Neural Network - DNN) gồm 5 tầng ẩn đã được thiết kế và triển khai trên nền tảng PyTorch. Lấy cảm hứng từ nghiên cứu nền tảng của Baldi và cộng sự (2014), kiến trúc mạng được xây dựng với số lượng nơ-ron giảm dần qua các tầng theo cấu trúc: $300 \rightarrow 300 \rightarrow 150 \rightarrow 75 \rightarrow 64$. Tại các tầng ẩn cấu trúc mạng tích hợp xen kẽ các lớp Chuẩn hóa theo lô (Batch


Normalization) để ổn định phân phối dòng dữ liệu, kết hợp cùng hàm kích hoạt phi tuyến tính ReLU nhằm duy trì cường độ tín hiệu qua nhiều tầng mạng. Đồng thời, kỹ thuật Dropout với tỷ lệ loại bỏ 30% ($p=0.3$) được áp dụng tại các tầng trên cùng để phá vỡ sự học thuộc lòng của hệ thống, từ đó triệt tiêu rủi ro quá khớp (overfitting) và tăng cường khả năng tổng quát hóa.

STT	Loại lớp (Layer Type)	Kích thước đầu ra	Thành phần bổ sung
0	Input Layer	(None, 28)	28 đặc trưng UCI
1	Fully Connected (Dense)	(None, 300)	ReLU, BatchNorm, Dropout(0.3)
2	Fully Connected (Dense)	(None, 300)	ReLU, BatchNorm, Dropout(0.3)
3	Fully Connected (Dense)	(None, 150)	ReLU, BatchNorm, Dropout(0.3)
4	Fully Connected (Dense)	(None, 75)	ReLU, BatchNorm, Dropout(0.3)
5	Fully Connected (Dense)	(None, 64)	ReLU
6	Output Layer (Dense)	(None, 1)	Sigmoid (BCE Loss)

Bảng 11: Kiến trúc mạng nơ-ron sâu 5 tầng (DNN 5-layer)

Quá trình truyền tải dữ liệu cũng được tối ưu hóa toàn diện cho phần cứng xử lý đồ họa (GPU). Sau khi chuẩn hóa bằng StandardScaler và chuyển đổi sang định dạng số thực 32-bit, dữ liệu được tải vào DataLoader với kích thước lô (batch size) lớn: 2048 cho tập huấn luyện và 4096 cho tập kiểm thử. Kết hợp cùng cơ chế ghim bộ nhớ (pin_memory), thiết lập này giúp tối đa hóa băng thông truyền tải dữ liệu từ RAM hệ thống sang VRAM của GPU, giải quyết triệt để hiện tượng nghẽn cổ chai trong tính toán.

Chiến lược huấn luyện được thực thi chặt chẽ trong vòng 30 chu trình (epochs) thông qua hàm mất mát Entropy chéo nhị phân tích hợp sẵn Sigmoid (BCEWithLogitsLoss), đảm bảo độ ổn định số học cao nhất khi tính toán gradient. Thuật toán tối ưu hóa Adam được sử dụng với tốc độ học khởi tạo $1e-3$ cùng tham số $weight_decay=1e-4$ đóng vai trò như một cơ chế điều chuẩn L2 để phạt các trọng số quá lớn. Đặc biệt, hệ thống sử dụng bộ lập lịch suy giảm tốc độ học theo hàm Cosine (CosineAnnealingLR), giúp tốc độ cập nhật trọng số giảm dần một cách mượt mà để mô hình hội tụ chính xác vào điểm cực tiểu. Cuối cùng, để bảo vệ kiến trúc sâu khỏi sự bất ổn của quá trình lan truyền ngược, kỹ thuật cắt xén đạo hàm (clip_grad_norm_) được thiết lập ở ngưỡng 1.0 nhằm ngăn chặn tuyệt đối hiện tượng bùng nổ đạo hàm (exploding gradients).



Hình 13: Biểu đồ Learning curve và training loss của mô hình DNN5

Dựa trên các biểu đồ trực quan hóa quá trình tối ưu hóa, mạng nơ-ron sâu 5 tầng (DNN 5-layer) thể hiện sự ổn định và hiệu năng hội tụ vượt trội qua 30 chu trình (epochs). Đồ thị hàm mất mát (Training Loss) sử dụng tiêu chí BCEWithLogits cho thấy sai số giảm mạnh ngay trong giai đoạn khởi đầu, chuyển dịch từ mức 0.32 xuống tiệm cận ngưỡng 0.19. Xu hướng này minh chứng cho khả năng tối ưu hóa trọng số hiệu quả của thuật toán, giúp mô hình nhanh chóng xác định được vùng tối ưu toàn cục mà không xảy ra hiện tượng dao động bất thường hay bùng nổ đạo hàm.

Về mặt hiệu năng định lượng, chỉ số Diện tích dưới đường cong ROC trên tập xác thực (Validation AUC) ghi nhận trạng thái bình ổn ở mức cực cao, đạt xấp xỉ 0.9755 ngay từ giai đoạn sớm của tiến trình. Việc duy trì đường tiệm cận ngang xuyên suốt các lần đánh giá (mỗi 5 chu trình) khẳng định mô hình đã đạt được sự cân bằng lý tưởng giữa năng lực học tập và khả năng tổng quát hóa, hoàn toàn không xuất hiện dấu hiệu quá khớp (overfitting) dù sở hữu cấu trúc sâu nhiều tầng. Đặc biệt, mức hiệu năng này hoàn toàn áp đảo so với mốc cơ sở 0.79 (biểu thị bằng đường nét đứt đỏ thấp hơn), khẳng định sự vượt trội của kiến trúc DNN 5 tầng kết hợp cùng bộ 28 đặc trưng UCI trong việc phân loại chính xác các tín hiệu vật lý năng lượng cao.

4.3.3. Kết quả huấn luyện

Mô hình (Nền tảng & Cấu hình)	Accuracy	AUC-ROC	F1-Score	Thời gian (s)
Logistic Regression (PySpark)	0.8163	0.8875	0.8158	7.8
Decision Tree (PySpark, depth=10)	0.8796	0.9204	0.8790	7.2
Random Forest (PySpark, 100 trees)	0.8909	0.9539	0.8905	132.9
GBT (PySpark, 100 iter, depth=5)	0.9112	0.9687	0.9110	160.5
XGBoost (CUDA, 300 trees)	0.9224	0.9751	0.9223	2.6
PyTorch DNN 5-layer (CUDA)	0.9211	0.9755	-	74.4

Bảng 12: Tổng hợp kết quả đánh giá các mô hình trên tập dữ liệu 28 đặc trưng

Đánh giá tổng quan kết quả:

Dựa trên bảng tổng hợp kết quả thực nghiệm, việc mở rộng không gian đặc trưng lên 28 biến chuẩn UCI cùng sự chuyển dịch sang nền tảng điện toán phân tán và tăng tốc phần cứng (GPU) cũng như cải thiện môi trường huấn luyện đã mang lại những bước tiến vượt bậc về mặt hiệu năng. Nhóm các thuật toán tăng cường và mạng nơ-ron sâu đã xác lập một mặt bằng tiêu chuẩn mới cho bài toán phân loại hạt Higgs.

Cụ thể, thuật toán XGBoost và mạng nơ-ron sâu PyTorch DNN 5-layer hiện đang dẫn đầu tuyệt đối với chỉ số AUC-ROC lần lượt đạt 0.9751 và 0.9755. Đây là mức hiệu năng tiệm cận sự hoàn hảo, minh chứng cho năng lực khai thác tối đa các tương tác phi tuyến tính trong nhóm 7 đặc trưng cấp cao (high-level features). Đáng chú ý, XGBoost thể hiện ưu thế vượt trội về mặt tối ưu hóa tài nguyên khi chỉ mất 2.6 giây để hoàn thành huấn luyện nhờ kiến trúc song song trên CUDA, trong khi DNN đòi hỏi thời gian thực thi lớn hơn (74.4 giây) để hội tụ trọng số qua 5 tầng mạng phức tạp. Bên cạnh đó, các mô hình Ensemble trên PySpark như GBT (Accuracy 91.12%) và Random Forest (Accuracy 89.09%) cũng ghi nhận mức độ ổn định cao, khẳng định vai trò của việc kết hợp đa mô hình trong việc giảm thiểu phương sai và sai số dự báo.

Phân tích so sánh đối chiếu với kết quả cũ:

Sự cải thiện rõ rệt nhất được ghi nhận khi đối chiếu hiệu năng của hai mô hình cơ sở là Hồi quy Logistic (LR) và Cây quyết định (DT) so với các thử nghiệm trên bộ dữ liệu 8 đặc trưng trước đó.

Đối với mô hình Hồi quy Logistic, mặc dù vẫn duy trì vị thế là mô hình có độ phức tạp thấp nhất, chỉ số Accuracy đã đạt mức 81.63%. Tuy con số này thấp hơn so với kết quả 85.40% của phiên bản cũ, nhưng cần phải xét đến bối cảnh thực nghiệm: mô hình hiện tại đang phải xử lý một không gian đặc trưng rộng hơn gấp 3.5 lần (28 so với 8) và quy mô dữ liệu lớn hơn. Chỉ số AUC-ROC duy trì ở mức 0.8875 cho thấy LR vẫn là một bộ lọc phân loại tuyến tính cực kỳ hiệu quả và đáng tin cậy trên nền tảng PySpark.


Sự chuyển biến tích cực nhất nằm ở mô hình Cây quyết định (DT). Ở các thử nghiệm cũ, DT bộc lộ rủi ro quá khớp nghiêm trọng khi không kiểm soát độ sâu. Trong phiên bản cải tiến này, việc can thiệp kỹ thuật vào cấu trúc cây (depth=10) đã mang lại kết quả bứt phá với Accuracy đạt 87.96% và AUC-ROC đạt 0.9204 (so với mức 83.64% và 0.8361 của phiên bản cũ). Việc tăng hơn 8% chỉ số AUC-ROC minh chứng rằng khi được giới hạn độ sâu một cách khoa học và cung cấp đầy đủ các đặc trưng khối lượng bất biến, Cây quyết định đơn lẻ hoàn toàn có khả năng thiết lập các luật phân tách chính xác mà không bị nhiễu loạn bởi các biến động cục bộ của dữ liệu.

Tựu trung lại, sự kết hợp giữa việc làm giàu dữ liệu và áp dụng các nền tảng tính toán hiện đại đã nâng tầm năng lực nhận diện tín hiệu vật lý của toàn bộ hệ thống mô hình, tạo ra một bước nhảy vọt đáng kể về cả độ chính xác lẫn tốc độ xử lý thực tế.

4.4. Trực quan hoá hiệu quả cải tiến

4.4.1. So sánh kết quả các mô hình cũ

So sánh độ chính xác:




Hình 14: Biểu đồ so sánh cải thiện độ chính xác LR và DT.

Dựa trên biểu đồ so sánh độ chính xác (Accuracy), việc nâng cấp bộ dữ liệu lên 28 đặc trưng chuẩn UCI và chuyển dịch sang môi trường điện toán phân tán (Phần B) đã mang lại những thay đổi đáng kể về mặt hiệu năng. Nhìn chung, các mô hình có kiến trúc phức tạp và phi tuyến tính đều ghi nhận sự tăng trưởng rõ rệt, khẳng định hiệu quả của việc làm giàu dữ liệu.

Mô hình LSTM tiếp tục xác lập vị thế dẫn đầu khi đạt mức 0.911 ở giai đoạn cải tiến, tăng đáng kể so với mức 0.893 ở giai đoạn cũ. Sự bứt phá ấn tượng nhất thuộc về mô hình Cây quyết định (DT) với mức tăng từ 0.836 lên 0.880. Kết quả này chứng minh rằng khi được cung cấp đầy đủ các đặc trưng cấp cao (high-level features) và kiểm soát cấu trúc phân nhánh tốt hơn trên PySpark, thuật toán dựa trên cây có thể khai thác thông tin vật lý sâu sắc hơn.

Ngược lại, mô hình Hồi quy Logistic (LR) ghi nhận sự sụt giảm nhẹ từ 0.854 xuống 0.816. Điều này có thể lý giải bởi sự gia tăng độ phức tạp của không gian 28 chiều, nơi các ranh giới phân tách phi tuyến tính trở nên phổ biến hơn, khiến một mô hình tuyến tính thuần túy gặp khó khăn trong việc bắt kịp tốc độ cải thiện của các đối thủ. Tuy nhiên, tất cả các mô hình trong cả hai giai đoạn đều duy trì mức hiệu suất vượt xa mốc tham chiếu 79% của nghiên cứu gốc IRJET, khẳng định sự thành công tổng thể của các giải pháp cải tiến môi trường huấn luyện.




Hình 15: Biểu đồ so sánh độ chính xác các mô hình.

Dựa trên biểu đồ tổng hợp, toàn bộ các mô hình thực nghiệm trong cả hai giai đoạn đều vượt xa mốc cơ sở 79% của nghiên cứu gốc, khẳng định tính hiệu quả vượt trội của các quy trình tiền xử lý và tối ưu hóa dữ liệu đã triển khai.

Trong giai đoạn cải tiến (Phần B), sự xuất hiện của các thuật toán nâng cao kết hợp với bộ 28 đặc trưng đã tạo ra một mặt bằng độ chính xác mới. XGBoost (GPU) và DNN 5-layer dẫn đầu tuyệt đối với chỉ số lần lượt là 0.922 và 0.921, xác lập giới hạn cao nhất về năng lực phân loại tín hiệu hạt Higgs trong phạm vi nghiên cứu. Các mô hình Ensemble như GBT (0.911) và Random Forest (0.891) cũng thể hiện sự ổn định và hiệu năng áp đảo so với các kiến trúc đơn lẻ ở giai đoạn trước.

Đáng chú ý, mô hình Cây quyết định (DT) ghi nhận sự nhảy vọt ấn tượng từ 0.836 lên 0.880 khi được tiếp cận các đặc trưng cấp cao. Ngược lại, Linear Regression là mô hình duy nhất ghi nhận sự sụt giảm độ chính xác (từ 0.854 xuống 0.816), cho thấy các ranh giới phân tách trong không gian 28 chiều mang tính phi tuyến tính phức tạp, dần vượt quá khả năng xử lý của các hàm tuyến tính thuần túy. Tựu trung lại, biểu đồ minh chứng rằng việc nâng cấp không gian đặc trưng và sử dụng các thuật toán học sâu là yếu tố then chốt để tối ưu hóa độ chính xác cho bài toán này.


So sánh độ tin cậy các mô hình.



Hình 16: Biểu đồ so sánh đường cong ROC của các mô hình.

Biểu đồ đường cong ROC cung cấp minh chứng trực quan về năng lực phân tách lớp xuất sắc của các mô hình thực nghiệm so với đường phân loại ngẫu nhiên ($AUC = 0.50$). Nhìn chung, các mô hình trong giai đoạn cải tiến (Phần B - đường nét liền) thể hiện sự áp đảo khi đẩy các đường cong tiệm cận sát góc trên bên trái của đồ thị, tương ứng với các giá trị AUC vượt trội.

Dẫn đầu về khả năng phân loại là mô hình DNN và XGBoost với chỉ số AUC đạt mức kỷ lục lần lượt là 0.976 và 0.975. Việc sở hữu diện tích dưới đường cong lớn nhất khẳng định các kiến trúc này có khả năng duy trì tỷ lệ nhận diện đúng (True Positive Rate) cực cao ở mọi ngưỡng quyết định mà không làm gia tăng đáng kể tỷ lệ báo động giả. Đáng chú ý, sự cải thiện của mô hình Cây quyết định (DT) được thể hiện rõ nét qua việc AUC tăng từ 0.836 lên 0.920, cho thấy ranh giới phân tách đã trở nên chuẩn xác hơn khi có thêm các đặc trưng cấp cao. Ngược lại, đường cong của Linear Regression là trường hợp duy nhất có xu hướng đi xuống (AUC giảm từ 0.933 xuống 0.887), phản ánh sự hạn chế của các hàm tuyến tính trong việc bắt kịp độ phức tạp phi tuyến của không gian dữ liệu mới. Tựu trung lại, các chỉ số AUC tiệm cận mức lý tưởng ở Phần B đã bảo chứng cho tính hiệu quả của chiến lược làm giàu đặc trưng và ứng dụng học sâu.




Hình 17: Biểu đồ so sánh ma trận tương quan.

Phân tích độ tin cậy thông qua các ma trận nhầm lẫn (confusion matrix) cho thấy sự chuyển biến rõ rệt về năng lực phân loại giữa hai giai đoạn thực nghiệm.

Trong giai đoạn cải tiến với 28 đặc trưng (Phần B), mô hình Cây quyết định (DT) đã xác lập mức độ tin cậy vượt trội. Tỷ lệ bỏ sót tín hiệu (False Negative) giảm mạnh từ mức 15.9% (Phần A) xuống chỉ còn 7.1%, trong khi tỷ lệ nhận diện đúng tín hiệu (True Positive) chạm ngưỡng 92.9%. Kết quả này minh chứng rằng việc bổ sung các đặc trưng cấp cao đã giúp thuật toán DT trở nên cực kỳ nhạy bén, giảm thiểu tối đa rủi ro mất mát các sự kiện vật lý quan trọng.

Ngược lại, mô hình Hồi quy Logistic (LR) bộc lộ sự suy giảm về độ ổn định trong không gian 28 chiều. Tỷ lệ báo động giả (False Positive) tăng lên mức 23.0%, cho thấy ranh giới phân tách tuyến tính không còn duy trì được độ chuẩn xác khi dữ liệu trở nên phức tạp hơn. Tựu trung lại, dữ liệu từ các ma trận khẳng định mô hình DT (28 feat) là kiến trúc có độ tin cậy cao nhất, đáp ứng tốt yêu cầu khắt khe về tính chính xác trong việc phân loại tín hiệu hạt Higgs Boson.

So sánh hiệu suất huấn luyện:



Hình 18: Biểu đồ so sánh thời gian huấn luyện mô hình.


Biểu đồ thời gian huấn luyện (biểu diễn theo thang đo log) cho thấy sự phân hóa rõ rệt về chi phí tính toán giữa các kiến trúc mô hình và các giai đoạn thực nghiệm. Nhìn chung, việc gia tăng độ phức tạp của dữ liệu lên 28 đặc trưng và quy mô mẫu trong Phần B đã đẩy mức tiêu thụ tài nguyên lên cao hơn so với giai đoạn tái hiện cơ sở.

Trong các mô hình chạy trên nền tảng CPU, thuật toán GBT (PySpark) ghi nhận thời gian huấn luyện lớn nhất với 160.5 giây, theo sau là Random Forest với 132.9 giây, phản ánh chi phí tính toán đặc thù của các phương pháp học máy kết hợp (Ensemble Learning) khi xử lý đa tầng dữ liệu. Ngược lại, điểm sáng công nghệ nổi bật nhất thuộc về XGBoost. Dù sở hữu cấu trúc phức tạp, nhờ tận dụng tối ưu khả năng tính toán song song của GPU (CUDA), mô hình này chỉ mất vỏn vẹn 2.6 giây để hoàn thành, đạt tốc độ vượt trội so với các đối thủ cùng phân khúc hiệu năng.

Tương tự, mạng nơ-ron sâu DNN 5-layer (74.4 giây) mặc dù có cấu trúc nhiều tầng ẩn nhưng vẫn đạt tốc độ hội tụ nhanh hơn đáng kể so với kiến trúc LSTM (116.3 giây) nhờ sự tối ưu hóa của thư viện PyTorch và tăng tốc phần cứng. Tựu trung lại, dữ liệu thời gian khẳng định rằng việc ứng dụng tăng tốc GPU là yếu tố tiên quyết để cân bằng giữa độ chính xác tối cao và hiệu quả vận hành thực tế.

4.4.2. Đánh giá các mô hình mới


Trực quan chỉ số đánh giá:



Hình 19: Biểu đồ tổng quát chỉ số đánh giá các mô hình

Dựa trên biểu đồ so sánh các chỉ số đo lường chi tiết trong giai đoạn cải tiến (Phần B), chất lượng phân loại của các mô hình thể hiện sự ổn định và hiệu năng cao một cách đồng nhất. Một đặc điểm kỹ thuật nổi bật là sự cân bằng lý tưởng giữa hai chỉ số Precision và Recall trên tất cả các kiến trúc. Việc ba cột chỉ số (F1, Precision, Recall) luôn duy trì độ cao tương đương nhau minh chứng rằng các mô hình đã đạt được trạng thái tối ưu, không bị thiên lệch về bất kỳ phía nào, đảm bảo vừa nhận diện chính xác tín hiệu hạt Higgs vừa tối thiểu hóa việc bỏ sót các sự kiện vật lý quan trọng.


Về mặt định lượng, nhóm các thuật toán học sâu và Ensemble tiếp tục khẳng định ưu thế tuyệt đối. XGBoost và DNN dẫn đầu với các chỉ số đồng loạt chạm ngưỡng 0.92, thể hiện năng lực tổng quát hóa dữ liệu xuất sắc trên không gian 28 đặc trưng. Theo sau sát sao là GBT với mức hiệu năng trên 0.91. Ngược lại, mô hình LR vẫn dừng lại ở mức cơ sở xấp xỉ 0.82, phản ánh giới hạn của các phương pháp tuyến tính trong việc bắt kịp độ phức tạp của dữ liệu mới. Tựu trung lại, sự ổn định của bộ ba chỉ số trên toàn hệ thống là minh chứng thép cho tính đúng đắn của quy trình tiền xử lý, giúp mô hình vận hành tin cậy trong các bài toán phân loại nhị phân phức tạp.



Hình 20: Biểu đồ chỉ số AUC-ROC các mô hình.

Dựa trên kết quả đo lường diện tích dưới đường cong ROC (AUC-ROC), các mô hình trong giai đoạn cải tiến thể hiện năng lực phân tách lớp và độ tin cậy cực kỳ ấn tượng. Toàn bộ hệ thống mô hình đều vượt xa mốc tham chiếu Azhari RF (0.812), khẳng định tính đúng đắn của việc áp dụng bộ 28 đặc trưng UCI kết hợp cùng các kỹ thuật tiền xử lý chuyên sâu.

Đứng đầu về độ tin cậy là mạng nơ-ron sâu DNN và thuật toán XGBoost với chỉ số lần lượt đạt 0.976 và 0.975. Những con số này tiệm cận mức lý tưởng và đạt sát ngưỡng của nghiên cứu hàng đầu Baldi DNN (0.98), minh chứng rằng mô hình có khả năng phân loại chính xác các sự kiện tín hiệu và nhiễu nền với sai số tối thiểu. Nhóm các thuật toán Ensemble như GBT (0.969) và Random Forest (0.954) cũng duy trì mức độ ổn định rất cao, củng cố ranh giới quyết định vững chắc. Ngay cả mô hình cơ sở như Cây quyết định (DT) cũng ghi nhận mức AUC đạt 0.920, cho thấy sự thăng tiến vượt bậc về độ tin cậy so với các phương pháp tuyến tính truyền thống (LR đạt 0.887). Tựu trung lại, chỉ số AUC-ROC ở mức cao đồng bộ trên toàn hệ thống đã bảo chứng cho khả năng ứng dụng thực tiễn của các mô hình trong việc nhận diện hạt Higgs Boson với độ chuẩn xác tuyệt đối.




Hình 21: Biểu đồ radar chỉ số các mô hình.

Biểu đồ Radar cung cấp cái nhìn toàn diện và trực quan về năng lực của các mô hình thông qua sự cân bằng giữa năm chỉ số cốt lõi: AUC, Accuracy, F1-Score, Precision và Recall. Dựa trên diện tích bao phủ của các đa giác, có thể thấy rõ sự phân cấp về hiệu năng và độ ổn định của từng kiến trúc.

Hai mô hình DNN và XGBoost thể hiện sự áp đảo tuyệt đối khi đa giác biểu diễn của chúng gần như trùng khớp và nằm ở lớp ngoài cùng, đạt giá trị tiệm cận ngưỡng 1.0 trên tất cả các trục đo lường. Điều này khẳng định năng lực phân loại toàn diện, không chỉ dừng lại ở độ chính xác thuần túy mà còn đạt được sự cân bằng lý tưởng giữa khả năng nhận diện đúng và việc kiểm soát báo động giả. Nhóm thuật toán Ensemble như GBT và Random Forest duy trì vị thế kế cận với hình dạng đa giác cân đối, minh chứng cho tính ổn định cao. Trong khi đó, mô hình LR nằm ở vị trí trong cùng với diện tích bao phủ nhỏ nhất, cho thấy những hạn chế nhất định trong việc bắt kịp các đối thủ học sâu. Tựu trung lại, sự tương đồng về hình thái của các đa giác trên biểu đồ bảo chứng cho việc hệ thống mô hình đều đạt được độ tin cậy cao và tính đồng nhất giữa các chỉ số đánh giá.


Đánh giá chuyên sâu các mô hình:



Hình 22: Biểu đồ ma trận nhầm lẫn mô hình Random Forest.

Ma trận nhầm lẫn của mô hình Rừng ngẫu nhiên (Random Forest) cung cấp bằng chứng thực nghiệm vững chắc về độ tin cậy và khả năng phân loại hiệu quả đối với dữ liệu hạt Higgs Boson. Với Độ chính xác (Accuracy) đạt 89.1% và chỉ số AUC ấn tượng 0.954, mô hình thể hiện sự cân bằng tối ưu giữa năng lực trích xuất đặc trưng và tính tổng quát hóa trên dữ liệu thực tế.


Phân tích chi tiết các chỉ số thành phần, mô hình cho thấy hiệu suất đặc biệt cao trong việc nhận diện lớp tín hiệu (True Signal). Tỷ lệ dự đoán đúng (Recall) đạt mức 93.1% (tương ứng với 22,121 sự kiện), đồng nghĩa với việc tỷ lệ bỏ sót tín hiệu (False Negative) chỉ chiếm 6.9%. Trong vật lý hạt thực nghiệm, việc tối thiểu hóa sai số loại II này là yếu tố quyết định để đảm bảo không bỏ sót các dấu vết lượng tử quan trọng. Ở chiều ngược lại, khả năng phân loại chính xác nhiễu nền (True Background) đạt 84.7%. Mặc dù vẫn tồn tại một tỷ lệ báo động giả (False Positive) nhất định là 15.3%, nhưng sự đánh đổi này là hoàn toàn hợp lý để ưu tiên cho độ nhạy của lớp tín hiệu. Tựu trung lại, cấu trúc ma trận tập trung mật độ cao tại đường chéo chính khẳng định Random Forest là một kiến trúc có độ ổn định và tin cậy cao trong hệ thống các mô hình cải tiến.



Hình 23: Biểu đồ ma trận nhầm lẫn mô hình Gradient Boost Tree.

Ma trận nhầm lẫn của mô hình Gradient Boosted Trees (GBT) triển khai trên nền tảng PySpark phản ánh mức độ tin cậy vượt trội trong việc phân loại các sự kiện Higgs Boson. Với độ chính xác tổng thể đạt 91.1% và chỉ số AUC chạm mức 0.969, mô hình đã thiết lập được một ranh giới quyết định cực kỳ vững chắc giữa tín hiệu vật lý và nhiễu nền trong không gian 28 đặc trưng.

Đi sâu vào khả năng nhận diện, thuật toán GBT thể hiện năng lực thu hồi tín hiệu (Recall) ấn tượng ở mức 93.8%, tương đương với 22,301 sự kiện được dự báo chính xác. Tỷ lệ sai sót loại II (bỏ sót tín hiệu) chỉ chiếm 6.2%, một con số lý tưởng cho các bài toán vật lý hạt thực nghiệm vốn đòi hỏi tính toàn vẹn cao của dữ liệu tín hiệu. Song song đó, khả năng phân loại nhiễu nền cũng đạt kết quả tích cực với tỷ lệ dự đoán đúng 88.1% (18,816 sự kiện). Mặc dù tỷ lệ báo động giả (False Positive) ghi nhận ở mức 11.9%, sự đánh đổi này là hoàn toàn hợp lý để duy trì độ nhạy tối đa cho các sự kiện tín hiệu lượng tử quý giá. Tóm lại, sự tập trung mật độ dự báo chính xác trên đường chéo chính của ma trận khẳng định GBT là một kiến trúc có độ ổn định và tính khả thi cực cao trong hệ thống.



Hình 24: Biểu đồ Features Importance mô hình Gradient Boost Tree.

Biểu đồ độ quan trọng đặc trưng (Feature Importance) của mô hình GBT khẳng định vai trò quyết định của nhóm đặc trưng cấp cao (high-level) đối với năng lực phân loại hạt Higgs. Kết quả thực nghiệm cho thấy sự áp đảo tuyệt đối của các biến khối lượng bất biến (invariant masses), minh chứng cho tính đúng đắn của việc mở rộng không gian đặc trưng từ 8 lên 28 biến chuẩn UCI.

Cụ thể, bốn đặc trưng có ảnh hưởng lớn nhất đến quyết định của mô hình đều thuộc nhóm cấp cao, bao gồm: m_{bb} (dẫn đầu với trọng số 0.2155), m_{wbb} , m_{wwbb} và m_{jlv} . Tổng trọng số tích lũy của nhóm này chiếm tỷ trọng áp đảo, cho thấy thuật toán GBT đã khai thác hiệu quả các tương tác vật lý phức tạp được tổng hợp sẵn để thiết lập ranh giới phân tách lớp chính xác. Trong khi đó, các đặc trưng cấp thấp (low-level) như $jet1_eta$ mặc dù đóng góp một phần quan trọng (0.0862), nhưng đa số các biến động học thô còn lại chỉ giữ vai trò hỗ trợ với trọng số thấp hơn đáng kể. Tựu trung lại, biểu đồ xác nhận rằng các biến cấp cao chính là yếu tố then chốt giúp mô hình GBT đạt được hiệu suất tối ưu, đồng thời phản ánh bản chất vật lý sâu sắc ẩn chứa trong dữ liệu.

4.4.3. Tổng kết những cải thiện đạt được

Quá trình thực nghiệm đã chứng minh rằng việc kết hợp đồng bộ giữa nâng cấp không gian đặc trưng, tối ưu hóa môi trường điện toán và ứng dụng các kiến trúc học máy tối tân đã tạo nên một bước nhảy vọt về hiệu năng nhận diện tín hiệu vật lý. Kết quả tổng thể cho thấy sự vượt trội toàn diện so với các nghiên cứu tham chiếu trước đây về cả độ chính xác lẫn tốc độ xử lý.

Cải tiến về phương diện dữ liệu:

Việc chuyển dịch từ bộ 8 đặc trưng cơ bản sang bộ dữ liệu đầy đủ 28 đặc trưng chuẩn UCI là yếu tố mang tính bước ngoặt. Việc bổ sung 7 biến số khối lượng bất biến cấp cao (high-level invariant mass features) đã cung cấp cho mô hình những thông tin vật lý cốt lõi, giúp đơn giản hóa quá trình học các quy luật phi tuyến phức tạp. Phân tích độ quan trọng đặc trưng (Feature Importance) đã khẳng định các biến số như m_{bb} , m_{wbb} đóng vai trò quyết định, trực tiếp đẩy chỉ số AUC-ROC của các mô hình cơ sở như Cây quyết định (DT) tăng từ 0.836 lên mức 0.920, đồng thời giảm thiểu đáng kể tỷ lệ bỏ lọt tín hiệu (False Negative) xuống mức thấp kỷ lục.

Tối ưu hóa hạ tầng huấn luyện:

Việc triển khai trên nền tảng PySpark và tăng tốc GPU (CUDA) đã giải quyết triệt để bài toán quy mô dữ liệu lớn. Sự chênh lệch cực đại về tốc độ huấn luyện giữa XGBoost (2.6 giây) và các mô hình chạy trên CPU thuần túy đã minh chứng cho hiệu quả của việc khai thác sức mạnh phần cứng. Nền tảng PySpark không chỉ giúp mô hình hóa dữ liệu trên quy mô 300.000 sự kiện một cách mượt mà mà còn thiết lập một khung làm việc (framework) sẵn sàng mở rộng cho các bài toán Dữ liệu lớn (Big Data) lên đến hàng chục triệu bản ghi trong tương lai.

Năng lực của các mô hình tối tân:

Sự xuất sắc của XGBoost và Mạng nơ-ron sâu 5 tầng (DNN) đã xác lập một tiêu chuẩn hiệu năng mới với Độ chính xác vượt ngưỡng 92.2% và chỉ số AUC tiệm cận mức lý tưởng 0.976. Các kiến trúc này không chỉ dẫn đầu về các chỉ số phân loại mà còn thể hiện sự cân bằng hoàn hảo giữa Precision và Recall qua biểu đồ Radar, phản ánh độ tin cậy tuyệt đối trong việc phân tách tín hiệu hạt Higgs khỏi nhiễu nền.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Tổng quan bài báo gốc

Nghiên cứu gốc được công bố trên tạp chí IRJET (2021) đã đặt nền móng quan trọng cho việc ứng dụng các thuật toán Học máy (Machine Learning) vào lĩnh vực vật lý năng lượng cao, cụ thể là bài toán phân loại hạt Higgs Boson. Trong bối cảnh các máy gia tốc hạt như LHC tại CERN tạo ra hàng tỷ sự kiện va chạm mỗi giây, việc nhận diện thành công sự tồn tại chớp nhoáng của hạt Higgs giữa một khối lượng khổng lồ dữ liệu "nhiều nền" (Background) là một thách thức cực đại đối với các phương pháp thống kê truyền thống. Nhóm tác giả của bài báo gốc đã tiếp cận vấn đề này thông qua lăng kính phân loại nhị phân (Binary Classification), biến đổi các thông số động học của tàn dư sau va chạm thành các vector đặc trưng để hệ thống có thể phân định giữa nhãn tín hiệu (Signal) và nhãn nhiễu nền.

Về mặt quy trình, nghiên cứu gốc đã triển khai một luồng công việc học máy tiêu chuẩn (ML Workflow) bao gồm các khâu từ thu thập dữ liệu, tiền xử lý, xây dựng mô hình, đến kiểm thử và đánh giá hiệu suất. Tập dữ liệu được sử dụng có quy mô 250.000 sự kiện, trích xuất từ nền tảng Kaggle và kho lưu trữ UCI, bao hàm một không gian đặc trưng khá khiêm tốn với 8 biến số vật lý cấp thấp (low-level features). Các biến số này đại diện cho các đặc trưng động học như khối lượng ước tính, độ giả nhanh (pseudo-rapidity), góc phương vị, và số lượng các luồng hạt (jets). Quá trình tiền xử lý dữ liệu được nhóm tác giả chú trọng thông qua việc rà soát dữ liệu khuyết thiếu, áp dụng phương pháp khoảng tứ phân vị (IQR) kết hợp kỹ thuật cắt xén (Winsorization) để không chế triệt để các giá trị ngoại lai (outliers) mà không làm suy giảm kích thước mẫu. Sau khi chuẩn hóa các dải giá trị bằng hệ số StandardScaler, dữ liệu được phân chia thành ba phần độc lập theo tỷ lệ 70% huấn luyện, 10% xác thực và 20% kiểm thử để phục vụ cho công tác mô hình hóa.

Đối với giai đoạn huấn luyện, bài báo gốc đã tiến hành đối chiếu hiệu năng của ba cấu trúc thuật toán tiêu biểu: Hồi quy tuyến tính/Logistic (Linear Regression), Cây quyết định (Decision Tree), và Mạng bộ nhớ ngắn hạn dài (LSTM). Dựa trên kết quả công bố của tài liệu gốc, mô hình Hồi quy tuyến tính cho kết quả thấp nhất với độ chính xác 67%, Cây quyết định đạt 72%, trong khi mạng nơ-ron LSTM thể hiện sự vượt trội khi chạm mốc 79%. Tuy nhiên, trong quá trình tái hiện lại thực nghiệm bằng các kỹ thuật tiền xử lý chặt chẽ và cấu hình siêu tham số tối ưu hơn, kết quả đạt được đã vượt xa hoàn toàn so với công bố ban đầu: mô hình Hồi quy vươn lên mức 85.40%, Cây quyết định đạt 83.6%, và LSTM củng cố vị thế dẫn đầu với độ chính xác 89.31% cùng chỉ số AUC-ROC cực kỳ ấn tượng là 0.9586.

Dù đạt được những kết quả khả quan trong việc tái hiện, quá trình phân tích chuyên sâu cũng đồng thời bộc lộ những hạn chế mang tính hệ thống của phương pháp tiếp cận trong bài báo gốc. Giới hạn nghiêm trọng nhất nằm ở việc chỉ sử dụng 8 đặc trưng thô, bỏ qua hoàn toàn các hàm phi tuyến

tính mô tả các khối lượng bất biến quan trọng, khiến mô hình thiếu đi nguồn thông tin vật lý cốt lõi. Thêm vào đó, việc giới hạn quy mô mẫu ở mức 250.000 sự kiện và thiếu vắng một tỷ lệ chia tách dữ liệu chuẩn mực (hold-out test set) đã tạo ra những nguy cơ tiềm ẩn về rò rỉ dữ liệu (data leakage). Đặc biệt, sự phụ thuộc hoàn toàn vào môi trường điện toán cục bộ (single-node) cùng việc không kiểm soát cấu trúc siêu tham số (điển hình là Cây quyết định phân nhánh mất kiểm soát đến độ sâu 49, tạo ra hơn 15.000 nút lá) đã khiến mô hình rơi vào trạng thái quá khớp (overfitting) trầm trọng, làm suy giảm mạnh khả năng tổng quát hóa trên dữ liệu thực tế. Những khuyết điểm chí mạng này chính là tiền đề thúc đẩy nhu cầu cấp thiết cho việc tái cấu trúc và nâng cấp toàn diện quy trình phân tích trong các giai đoạn tiếp theo.

5.2. Kết quả cải tiến đạt được

Nhằm khắc phục triệt để những rào cản và hạn chế từ nghiên cứu gốc, dự án đã triển khai một chiến lược cải tiến toàn diện, bao phủ từ khâu làm giàu không gian dữ liệu, tối ưu hóa hạ tầng điện toán, cho đến việc ứng dụng các kiến trúc mạng học sâu tối tân. Về mặt dữ liệu, nâng cấp mang tính đột phá nhất là việc mở rộng không gian đặc trưng từ 8 biến lên thành 28 biến chuẩn hóa thuộc kho lưu trữ UCI. Sự mở rộng này không chỉ gia tăng về lượng mà còn tạo ra sự thay đổi về chất khi tích hợp trực tiếp 7 đặc trưng cấp cao (high-level invariant mass features) như m_{bb} , m_{wbb} , m_{wwbb} . Đây là những thông số đại diện cho các định luật bảo toàn khối lượng và năng lượng, cho phép các thuật toán học máy trực tiếp nắm bắt các tương tác hạt vật lý phức tạp mà không phải tiêu tốn tài nguyên để tự suy luận từ dữ liệu thô. Cùng với việc gia tăng quy mô huấn luyện lên 300.000 sự kiện, dự án đã thiết lập lại tỷ lệ phân chia dữ liệu chuẩn mực và nghiêm ngặt 70% Train, 15% Validation, và 15% Test, đảm bảo tính khách quan tuyệt đối khi đánh giá năng lực dự báo.

Để hiện thực hóa sức mạnh xử lý trên tập dữ liệu đa chiều, môi trường thực nghiệm đã được dịch chuyển hoàn toàn khỏi nền tảng tính toán cục bộ truyền thống. Thay vào đó, hệ thống ứng dụng kiến trúc tính toán phân tán PySpark thông qua thư viện MLlib, kết hợp cùng sức mạnh xử lý song song từ bộ vi xử lý đồ họa (GPU - CUDA). Bước tiến công nghệ này đã triệt tiêu hoàn toàn rủi ro tràn bộ nhớ (Out-Of-Memory) từng tồn tại, đồng thời tạo ra một đường ống (pipeline) xử lý dữ liệu với tốc độ siêu tốc. Dựa trên nền tảng vững chắc này, dự án đã thay thế các mô hình đơn lẻ yếu kém bằng các kỹ thuật Học tập kết hợp (Ensemble Learning) như Random Forest (100 cây quyết định), Gradient Boosted Trees (GBT), và đặc biệt là cực trị tăng cường độ dốc XGBoost. Không dừng lại ở đó, một Mạng nơ-ron sâu (DNN) bao gồm 5 tầng ẩn (theo cấu trúc $300 \rightarrow 300 \rightarrow 150 \rightarrow 75 \rightarrow 64$) đã được xây dựng trên PyTorch, tích hợp đầy đủ các kỹ thuật chuẩn hóa tiên tiến như Batch Normalization, hàm kích hoạt ReLU, và Dropout (30%) để ngăn ngừa hiện tượng quá khớp.

Kết quả đánh giá thực nghiệm (thu được trên tập 28 đặc trưng) đã minh chứng sức mạnh áp đảo của các giải pháp cải tiến, thiết lập một mặt bằng tiêu chuẩn hoàn toàn mới cho bài toán phân

loại hạt Higgs. Thuật toán XGBoost chạy trên nền tảng CUDA và kiến trúc PyTorch DNN 5-layer đã dẫn đầu tuyệt đối, với chỉ số Diện tích dưới đường cong ROC (AUC-ROC) lần lượt chạm mức kỷ lục 0.9751 và 0.9755, kèm theo độ chính xác tổng thể duy trì ổn định ở mức trên 92%. Đáng kinh ngạc hơn, việc tối ưu hóa phần cứng đã giúp XGBoost hoàn thành quá trình hội tụ trên toàn bộ dữ liệu chỉ trong vòng 2.6 giây, một tốc độ không tưởng nếu so sánh với thời gian 116.26 giây của kiến trúc LSTM cũ. Các chỉ số đo lường chi tiết khác như F1-Score, Precision và Recall của các mô hình mới đều tạo thành một trạng thái cân bằng lý tưởng (đều xấp xỉ 0.92), khẳng định khả năng phát hiện tín hiệu chính xác đi kèm với tỷ lệ báo động giả (False Positive) và tỷ lệ bỏ lọt tín hiệu (False Negative) cực kỳ thấp.

Một minh chứng rõ nét khác cho hiệu quả của việc cải tiến là sự phục hồi của thuật toán Cây quyết định (Decision Tree). Khi được tiếp cận với không gian 28 đặc trưng và kiểm soát chặt chẽ độ sâu ở mức 10, mô hình DT đã có bước nhảy vọt từ mức Accuracy 83.64% lên 87.96%, đồng thời nâng chỉ số AUC-ROC từ 0.8361 lên 0.9204. Phân tích từ biểu đồ độ quan trọng đặc trưng (Feature Importance) của mô hình GBT đã giải thích hiện tượng này: các biến số khối lượng bất biến cấp cao (đặc biệt là m_{bb} và m_{wbb}) đóng góp trọng số phân loại lớn nhất, chi phối hoàn toàn khả năng ra quyết định của các thuật toán. Sự chi phối này khẳng định rằng, việc mở rộng dữ liệu và áp dụng các kỹ thuật tính toán chuyên sâu không chỉ giải quyết trọn vẹn các khuyết điểm của bài báo gốc mà còn thực sự khai phá được bản chất vật lý lượng tử ẩn giấu bên trong các tập số liệu khổng lồ.

5.3. Phương hướng phát triển dự án trong tương lai

Dựa trên những thành tựu đột phá đã được ghi nhận ở phần cải tiến, dự án sở hữu một tiềm năng to lớn để tiếp tục phát triển và mở rộng trong các nghiên cứu tương lai. Điểm tựa vững chắc nhất chính là hệ thống hạ tầng điện toán phân tán PySpark đã được thiết lập thành công. Mặc dù các kết quả tối ưu hiện tại được kiểm chứng trên tập mẫu 300.000 sự kiện, kiến trúc đường ống (ML Pipeline) hoàn toàn đủ năng lực và độ sẵn sàng để xử lý trọn vẹn bộ dữ liệu khổng lồ chứa 11.000.000 bản ghi của kho lưu trữ UCI mà không cần phải viết lại mã nguồn. Việc xử lý trực tiếp trên quy mô Dữ liệu lớn (Big Data) ở cấp độ hàng chục triệu bản ghi sẽ cung cấp một bức tranh toàn cảnh và chính xác tuyệt đối về các hiện tượng va chạm hạt. Để hiện thực hóa điều này, phương hướng sắp tới sẽ tập trung vào việc triển khai hệ thống trên các cụm máy chủ đám mây phân tán (Cloud Clusters) quy mô lớn, tinh chỉnh cơ chế phân mảnh bộ nhớ của Apache Spark nhằm tối ưu hóa chi phí tính toán (overhead) giữa các nút mạng (worker nodes).

Bên cạnh việc mở rộng quy mô dữ liệu, khâu tinh chỉnh siêu tham số (Hyperparameter Tuning) cần được nâng cấp từ hình thức thử nghiệm thủ công sang các cơ chế tự động hóa quy mô lớn (AutoML). Trong bối cảnh cấu hình hiện tại đã ứng dụng các lưới tìm kiếm (GridSearch) và xác thực chéo (CrossValidator), tương lai của dự án có thể hướng đến việc tích hợp các phương pháp tối

ưu hóa tiên tiến hơn như Tối ưu hóa Bayes (Bayesian Optimization). Kỹ thuật này sẽ giúp hệ thống dò quét không gian tham số của các kiến trúc học sâu (DNN, XGBoost) một cách thông minh và định hướng hơn, tiết kiệm đáng kể tài nguyên GPU. Việc tìm ra tổ hợp siêu tham số tối ưu tuyệt đối sẽ góp phần đẩy chỉ số AUC-ROC của mô hình vượt qua ranh giới 0.98 của Baldi (2014) để tiệm cận hơn nữa mức hoàn hảo 1.0 trong thực nghiệm vật lý năng lượng cao.

Về mặt kiến trúc thuật toán, mặc dù Mạng nơ-ron sâu 5 tầng (DNN) đã thể hiện sức mạnh nhận diện phi tuyến tính xuất sắc, lĩnh vực trí tuệ nhân tạo vẫn không ngừng tiến hóa. Các hướng đi tương lai có thể khai phá sức mạnh của các kiến trúc Mạng nơ-ron đồ thị (Graph Neural Networks - GNNs) hoặc cơ chế Transformer. Do đặc tính của các sự kiện vật lý hạt thường chứa các luồng tia (jets) có sự tương tác vật lý phức tạp trong không gian đa chiều, GNN có thể mô hình hóa trực tiếp sự phụ thuộc cấu trúc giữa các hạt tàn dư. Điều này hứa hẹn sẽ khai thác thêm nhiều chiều thông tin ẩn mà các kiến trúc truyền thống dựa trên vector phẳng (như DNN hay XGBoost) chưa thể tiếp cận trọn vẹn. Thêm vào đó, việc phân tích ngược lại bộ trọng số hoặc ma trận "Feature Importance" của các mô hình này sẽ hỗ trợ giới khoa học vật lý lượng tử khám phá thêm các hàm khối lượng bất biến mới, tạo ra vòng lặp cộng sinh giữa Trí tuệ nhân tạo và Vật lý lý thuyết.

Cuối cùng, hướng phát triển mang tính ứng dụng thực tiễn cao nhất là triển khai các mô hình phân loại đã được đào tạo (pre-trained models) thành các luồng suy diễn theo thời gian thực (real-time inference pipelines). Trong môi trường vận hành thực tế tại hệ thống Máy gia tốc hạt Lớn (LHC), dữ liệu va chạm được sản sinh liên tục dưới dạng dòng chảy (streaming data). Việc kết hợp bộ khung dự báo hiện tại với các công nghệ xử lý luồng như Apache Kafka hay Spark Structured Streaming sẽ cho phép hệ thống tự động nhận diện và cô lập các tín hiệu Higgs Boson ngay tại thời điểm chúng vừa được máy dò ghi nhận. Khả năng phát hiện và lưu trữ theo thời gian thực không chỉ giúp tiết kiệm không gian bộ nhớ vật lý tại CERN (bằng cách loại bỏ ngay lập tức các sự kiện nhiễu nền) mà còn đóng góp trực tiếp vào công cuộc tìm kiếm các dạng hạt cơ bản hiếm gặp hơn nữa trong nỗ lực hoàn thiện Mô hình Chuẩn (Standard Model) của nhân loại.

TÀI LIỆU THAM KHẢO

1. Chaukate, V., et al. (2021), Higgs Boson Discovery using Machine Learning, International Research Journal of Engineering and Technology, 8(12), p. 1548.
2. Azhari, M., et al. (2020), Higgs boson discovery using machine learning methods with pyspark, Procedia Computer Science, 170, pp. 1141-1146.
3. Baldi, P., Sadowski, P., Whiteson, D. (2014), Searching for exotic particles in high-energy physics with deep learning, Nature Communications, 5, p. 4308.
4. Baldi, P., Sadowski, P., Whiteson, D. (2014), HIGGS Dataset, UCI Machine Learning Repository.
5. Adam-Bourdarios, C., et al. (2015), The Higgs boson machine learning challenge, Proceedings of Machine Learning Research, 42, pp. 19-55.
6. Meng, X., et al. (2016), MLlib: Machine Learning in Apache Spark, Journal of Machine Learning Research, 17(34), pp. 1-7.